

Contents

DACON 모기비행 우승자 격차 분석—내 LB 0.6862 는 어디서 0.70+ 에 닿지 못했나	1
이 문서는 무엇인가	1
목차	2
1. 요약—한눈에 보는 격차	2
2. 내 접근법 정리 (파이프라인 순서)	5
3. 우승자 공통 패턴 (0.70+ 5 명에서 반복되는 것)	10
4. 단계별 심층 비교 (전처리 → 피쳐 → 모델 → 검증 → 앙상블/후처리)	16
5. 우승자 간 차이 (0.70+ 안에서 갈리는 선택)	24
6. 다음 도전을 위한 체크리스트	29

DACON 모기비행 우승자 격차 분석—내 LB 0.6862 는 어디서 0.70+ 에 닿지 못했나

대 회: DACON 모 기 비 행 궤 적 예 측 (comp 236716, 종 료 2026-06-01) · 지 표: hit@1cm metric(예 측 한 +80ms 후 3D 위치가 정답과 1cm(0.01m) 이내면 그 샘플은 1 점 (맞음), 아니면 0 점을 주는 이진 적중률 지 표—'평균 거리'가 아니라 '1cm 경계를 넘었느냐'로 점수가 갈리는 이 대회 채점 지표이며, 모든 설계 결정의 뿌리 가 된다) · 문제: 11 스텝 (40ms 간격) 3D 궤적 → +80ms 위치 한 점.

이 대회가 무엇을 시키나—먼저 그림부터. 모기 한 마리가 날아간 마지막 0.4 초 (=400ms) 동안의 위치를 40ms 간격으로 11 개 찍어서 준다. 즉 입력은 3D 좌표 (x, y, z) 11 개로 이뤄진 짧은 궤적 한 토막이다. 과제는 그 직후 80ms(0.08 초) 뒤에 모기가 어디 있을지 (x, y, z) 단 한 점 (one point in 3D) 을 맞히는 것이다—11 개 입력에서 미래의 1 개 출력을 뽑는 구조다. 채점은 그 예측한 한 점이 실제 위치와 1cm(0.01m) 안이면 그 샘플은 1 점 (맞음), 밖 이면 0 점이다. 그래서 점수 (score) 는 전체 테스트 모기들 중 '1cm 안에 들어온 비율'이 되고, 0.6862 점이라는 건 약 68.6% 를 1cm 안에 맞췄다는 뜻이다. ('1 점'은 score 단위, '한 점'은 3D 위치 한 개를 가리킨다—헛갈리지 말 것.)

이 문서는 무엇인가

내가 이 대회에서 끝내 도달한 최고점은 KR008 —leaderboard(LB) 0.6862(LB 는 대회의 실제 채점 점수로, 전체 테스트셋 약 1 만 개에서 측정돼 OOF 보다 미세 시프트를 통계적으로 더 잘 잡아낸다. Public/Private 두 가지가 있 고 Private 가 최종 순위를 결정하는 서플된 채점이다) 다. 모델은 단일 Kalman filter(과거 관측의 노이즈를 평활하 는 고전 필터) 위에 잔차 (residual = 정답에서 baseline 예측을 뺀 차이—절대 위치를 직접 맞히는 대신, baseline 이 틀린 만큼만 신경망이 배우게 하는 것) 를 얹어 학습하는 GRU(Gated Recurrent Unit —시계열 패턴을 배우는 신경 망) 다. 한마디로 단일 모델 하나로 푼 파이프라인이다 (모델 내부 디테일은 §2 에서 푼다).

Kalman filter 가 이 문서 내내 baseline 핵심 부품이니 그림부터 잡자. 관측된 11 개 좌표는 노이즈투성이라, 매 스텝 관측을 100% 믿어 버리면 궤적이 떨린다. 그래서 Kalman 은 등속 운동을 가정해 예측한 다음 위치와 실제 관측을 각각의 신뢰도에 따라 가중평균해 흔들림을 줄이고, 그렇게 평활된 속도로 +80ms 를 외삽한다. 이때 매 스텝의 '예측 — 관측' 차이 (innovation) 가 곧 그 샘플의 노이즈 크기 추정이 되고, 평활된 속도 (filtered_v) 같은 부산물은 그대로 피쳐로도 쓸 수 있다. 가장 단순한 baseline 인 F0(마지막 점 + (마지막 — 직전) 속도로 한 스텝만 외삽) 와 대비하면 차이가 분명하다—F0 는 마지막 1 스텝의 속도만 쓰지만, Kalman 은 과거 11 스텝 전체를 평활해서 속도를 추정하므 로 base 예측 품질이 더 높고, 잔차 학습이 출발하는 토대가 더 좋아진다.

공개 코드공유 (codeshare) 에서 Private 0.70 을 넘긴 우승자 5 명의 실제 코드를 내려받아 내 파이프라인과 같은 표·같은 단계로 해부하고, “우승자 수준에 닿으려면 어디서 무엇을 떠올렸어야 했나”를 배우기 위한 자료다. 이하 우 승자를 부르는 등수 (1~5 위) 는 이 0.70+ 5 인의 score 순위이며, 4 위·5 위의 정확한 DACON private 순위는 비공 개다 (이 면책은 여기서 한 번만 풀어 두고, 뒤 섹션에서는 '등수 =score 순'으로만 짚는다).

독자는 “나”(이 코드를 짰 본인) 이며, 내 접근법조차 개념적으로만 안다고 가정한다. 그래서 전문용어는 처음 나올 때

괄호로 한 문장씩 풀고, 왜 이 단계가 필요한가 → 무엇을 하는가 → 그래서 점수가 왜 오르는가의 흐름으로, 데이터가 들어와 점수가 나오기까지의 파이프라인 순서로 서술한다.

읽는 법. 핵심은 비교 지점마다 끼워 둔 [💡 내가 떠올렸어야 한 것] 블록 (주황 박스) 이다. “나는 X 까지는 했지만 Y 라는 발상을 못 했다 / 그 발상은 ~ 한 관찰에서 나올 수 있었다”는 형식으로, 내가 이미 손에 쥐고 있던 단서에서 우승자의 도약이 어떻게 나올 수 있었는지를 짚는다. 한 가지만 미리 못박자—이 💡 블록들은 “개념적으로 떠올렸어야 할 도약”을 말하지, “이 기법이 몇 점 올렸다”는 정량 분해를 주장하지 않는다. 1 위의 여섯 구성요소 (다양성 ensemble·공통 backbone·Soft R-Hit 손실·cache 사전학습·Y-flip TTA· θ -oversample) 도 개별 기여도 (per-lever Δ LB) 는 측정되지 않았다. 이 문서가 단언하는 수치는 측정된 것 (전체 격차 +0.0168, 두 예측의 거리분포, 내 lane 의 OOF/LB 실측) 뿐이다.

목차

1. 요약—한눈에 보는 격차: 내 최고 vs 우승자 5 명 점수표, 격차의 정체 한 문단.
2. 내 접근법 정리: FO → plan-004 framework → Kalman residual(잔차—정답에서 baseline 예측을 뺀 차이, 즉 정답 — baseline 예측. 절대 좌표를 직접 맞히는 대신 baseline 이 틀린 만큼만 신경망이 배우게 하면 학습할 양 (타깃 분산) 이 작아져 학습이 안정되고 경계 샘플 정밀도가 올라간다) GRU(KR008) 와 CV-LB 과리, 그리고 죽은 시도들.
3. 우승자 공통 패턴: 0.70+ 5 명이 반복한 여섯 결정과 왜 효과적인가.
4. 단계별 심층 비교: 전처리 → 피쳐 → 모델 → 검증/학습 → 앙상블 (ensemble = 여러 모델의 예측을 평균/가중평균해 하나의 최종 예측을 만드는 기법—우승자들의 핵심으로, 단일 모델 30 복제가 아니라 성질 다른 모델을 섞을 때 효과가 극대화된다)/후처리, 각 단계 (a) 나 (b) 우승자 (c)💡.
5. 우승자 간 차이: 0.70+ 안에서 갈린 노선과 트레이드오프 (복잡도 $\neq$ 점수).
6. 다음 도전 체크리스트: 다음 챌린지에서 스스로 통과시킬 질문 9 개.

1. 요약—한눈에 보는 격차

이 대회에 채점 지표는 hit@1cm —우리 모델이 찍은 +80ms 후 3D 위치가 정답과 1cm(0.01m) 이내면 1 점, 아니면 0 점인 binary metric(이진 지표—맞았다 (1)/틀렸다 (0) 로만 채점되는 미분 불가 지표. 0.9cm 는 만점, 1.1cm 는 뺄점인 ‘절벽’구조라 분산이 크고 1cm 경계 샘플에서 둔감해, 평균 거리를 줄이는 일반 회귀 손실과 보상 방향이 어긋난다) 이다. 입력은 모기 궤적 11 스텝 (40ms 간격, 마지막 -400ms~0ms) 의 3D 좌표이고, 출력은 그 직후 +80ms 시점의 위치 하나다. 미세한 좌표 오차가 1cm 경계를 넘느냐 마느냐로 점수가 갈리는, “거의 다 맞히지만 마지막 0.x cm 에서 승부 나눈”종류의 문제다. (근거: EXPERIMENTS.md, analysis/plan-a-001/)

내가 끝내 도달한 최고점은 KR008: LB 0.6862 / OOF 0.6671(단일 Kalman 잔차 GRU) 이다. 반면 DAICON 공개 (comp 236716 codeshare) 의 0.70+ 5 인은 모두 이 선을 넘었다 (이하 등수는 이 0.70+ 5 인의 score 순위이며, 4 위·5 위의 정확한 DAICON private 순위는 비공개다). 격차는 1 위 대비 -0.0173, 5 위 (0.700) 대비 -0.0138. 숫자만 보면 1.4~1.7%p 의 작은 차이지만, 이진 hit 지표에서 이 폭은 “1cm 경계에 걸친 샘플 수백 개의 hit/miss 가 통째로 뒤집힌”결과다. 실제로 1 위와 내 KR008 의 예측 좌표는 평균 0.22cm 밖에 안 떨어져 있고 97.4% 가 서로 1cm 이내, P95 도 0.64cm 다 (plan-w-001.results.md §3). 즉 1 위는 나보다 “한참 다른 답”을 낸 게 아니라, 경계에 걸린 샘플을 1cm 안쪽으로 밀어 넣는 미세 보정을 나보다 잘했을 뿐이다. 이 사실이 이 자료 전체의 출발점이다—격차의 정체는 거대한 알고리즘 격변이 아니라, 같은 풀 (pool) 에서 출발해 마지막 0.x cm 를 다듬는 여러 겹의 장치다.

표 1. 점수표—우승자 5 명 vs 내 최고 (KR008)

이 표는 한 가지만 말한다—점수 격차가 작다 (나와 1 위가 +0.0173 밖에 안 벌어졌다). paradigm 칸은 일단 ‘직관 한 줄’로만 읽고, 칸 안의 정확한 기술명 (Neural-ODE, Frenet, DE 블렌드 등) 은 표 아래 풀이와 §3·§4 에서 차차 본다. 지금은 “1 위는 성질 다른 모델을 30 개 섞었고, 나는 한 개만 썼다”는 그림만 잡으면 된다.

순위	Private score	paradigm(직관 한 줄)	KR008(0.6862) 대비 Δ
1 위	0.7035 (재현 0.703)	성질 다른 모델 3 종을 30 개 섞음	+0.0173
2 위	0.7031	메커니즘이 다른 4 가지 풀 ~40 개를 섞음	+0.0169
3 위	0.7019	강한 모델 1 개 + 보조 1 개를 가중 평균 ($w=0.96$)	+0.0157
4 위	0.7011	물리 모델 + 잔차 모델을 15 개 (3×5) 섞음	+0.0149
5 위	0.700	1 개 모델로 물리계수 예측 + 경계 보정 1 개, 10 개 섞음	+0.0138
내 최고: KR008	LB 0.6862 / OOF 0.6671	단일 모델 1 개 (잔차 GRU, 섞기·증강 없음)	—(기준)

주 (근거 명시): score 는 모두 DCON comp 236716 codeshare 의 Private 점수다. 단, **2 위는 ~40 멤버 base 가 노트북에 zlib+base64 로 압축 내장 (BASE64) 되어 멤버별 코드가 비공개 (notebook Cell 22 MD), 3 위는 본문에 Private score 텍스트가 없고 OOF 0.6744 만 박제 (rank3 노트북 cell 6589-6604, Private 0.7019 는 외부 리더보드 정보), 4 위·5 위도 노트북 본문엔 “LB 0.699 베이스”, “Public 0.7022/Private 0.700”만 명시되고 일부 OOF 절대수치는 HTML 출력에 미포함이다. 즉 점수 비교는 가능하되, per-기법 Δ LB(어느 장치가 몇 점 올렸는지) 는 1~5 위 누구도 측정·공개하지 않았다.** 아래 § 들에서 per-lever 수치를 단언하지 않는 이유다.

표와 본문에 거듭 나올 네 단어부터 먼저 깔고 가자—이 넷은 파이프라인을 이해하는 최소 도구다. 나머지 모델 이름 (Neural-ODE 등) 과 섞는 방식 (블렌드 등) 은 실제로 쓰이는 §3·§4 에서 그때 정의한다.

- LB(리더보드—표의 score 는 모두 LB 의 Private 점수다. 대회가 실제로 채점하는 점수이자, 전체 테스트셋 약 1 만 개에서 측정된다).
- OOF(out-of-fold / cross-validation —학습에 쓰지 않은 검증 조각 (fold) 들을 모아 만든 정직한 내부 예측·점수. 내 손안의 작은 검증셋이라 보면 된다. 이진 지표의 노이즈 위에서 이 기법이 진짜 효과 있나?를 판단하는 토대지만, 1cm 경계 샘플의 미세 개선에는 둔감할 수 있다).
- baseline(베이스라인—신경망이 손대기 전에 ‘쉬운 부분 (등속 직진)’을 공식으로 미리 깔아두는 기준 예측. linear extrapolation·Kalman filter·학습형 물리코어 등이 그 역할을 한다. baseline 이 좋을수록 신경망이 메워야 할 차이가 작아져 분산이 준다).
- residual(잔차—정답에서 baseline 예측을 뺀 차이. 좌표를 통째로 맞히는 대신 baseline 이 틀린 만큼만 신경망이 배우게 하는, 우승자 공통의 학습 타깃이다).

여기서 한 가지 직관을 미리 깔아둔다 (이 문서 전체의 핵심 인과). 우승자들이 거듭 노린 건 ‘1cm 경계에 걸린 샘플’이다. 그런데 어떻게 손실 함수가 경계 샘플만 골라 집중할까? 답은 sigmoid(S 자 곡선) 의 기울기에 있다. sigmoid 는 입력 (예측 오차 거리) 이 경계 (1cm) 에서 멀면—0.3cm 처럼 확실히 맞췄거나 3cm 처럼 확실히 틀렸으면—출력이 거의 0 또는 1 로 평평해서 기울기 (gradient) 가 0 에 가깝다. 오직 1cm 근처에서만 0→1 로 가파르게 꺾여 기울기가 최대가 된다. 학습은 이 gradient(기울기) 가 큰 샘플일수록 그 샘플을 고치는 쪽으로 가중치를 더 크게 움직인다 (gradient = 학습 신호의 세기). 따라서 이미 맞춘 (0.3cm)·이미 틀러먹은 (3cm) 샘플은 거의 무시되고, 0.9~1.1cm 경계에 아슬아슬하게 걸린 샘플에만 보정 예산이 쏠린다. 우승자들의 ‘hit’ 를 직접 최적화하는 손실 ‘뒤의 Soft R-Hit’ 이 점수를 올리는 메커니즘이 바로 이것이다. 곡선의 ‘가파른 구간’을 정하는 손잡이가 temperature τ 인데, 자세한 손실 설계는 §3·§4 에서 본다.

어디서 갈렸는가—격차 한 문단 압축

다섯 우승자의 비법은 다섯 개의 축으로 누를 수 있다. 여기서는 각 축의 이름과 한 줄 직관, 그리고 누가 썼나만 적는다. 각 축의 자세한 메커니즘과 전문용어는 그 기법이 본격 등장하는 §3·§4 에서 푸니, 지금은 ‘이런 다섯 갈래가 있구

나'하는 지도만 챙기면 된다.

- (1) 다양성 블렌드—성질이 다른 (틀리는 방향이 다른) 모델을 여러 개 섞어 오차를 상쇄한다. 같은 잔차 베이스 위에 GRU·ODE·Frenet 제어·회전물리처럼 작동 원리가 다른 모델을 얹으면, 한 모델이 경계 밖으로 민 샘플을 다른 모델이 안으로 당겨준다 (1 위 30 개, 2 위 ~40 개, 3 위 2 개, 4 위 15 개). 단순 ensemble(여러 모델의 예측을 평균/가중평균해 하나의 최종 예측을 만드는 기법—우승자들의 핵심으로, 같은 모델 30 복제가 아니라 성질 다른 모델을 섞을 때 효과가 극대화된다) 에서 출발하지만, 핵심은 '같은 모델 복제'가 아니라 '다른 모델 섞기'다. → 자세한 건 §3(c).
- (2) 지표 정렬 손실—평균 거리 (MSE) 를 줄이는 게 아니라 1cm 적중 자체를 직접 노린다. 손실도 hit 기준으로, 학습을 멈추는 기준 (early-stop) 도 'val loss 최저'가 아니라 'val hit-rate 최고'로 끝까지 관찰했다 (1·2·3·4 위). 위 blockquote 의 sigmoid 직관이 이 축의 동력이다. → 자세한 건 §3(d).
- (3) 물리 + 신경망—순수 데이터 학습 대신 물리 사전지식 (회전·적분·감쇠) 을 신경망에 구조로 주입한다. 급선회 (뱅크 턴) 같은 곡선 궤적을 데이터로 유연히 배우길 기대하지 않고 회전 공식으로 못 박아, 1cm 가 잘 깨지는 커브를 구조적으로 잡는다. → 자세한 건 §4 모델 단계.
- (4) 잔차·계수 학습—좌표를 직접 맞히지 않고, baseline 위의 잔차만 혹은 운동방정식 계수만 학습해 배울 양 (분산) 을 줄인다. 신경망이 0 에 가까운 작은 보정만 배우면 되니 학습이 안정되고 경계 정밀도가 오른다 (5 위는 좌표 대신 물리계수 6 개를 회귀). → 자세한 건 §4 모델 단계.
- (5) 어려운 샘플 더 보기 + 추론 안정화—hit 이 주로 깨지는 급선회 샘플을 더 자주 학습시키고 (oversampling, 최대 5×; 1·2·3·4 위), 추론 때 입력을 좌우대칭으로 뒤집어 평균 (TTA; 1 위) 해 경계 샘플의 흔들림을 줄인다. 약한 고리 (급커브) 에 학습·추론 예산을 몰아준다. → 자세한 건 §4 학습·후처리 단계.

내 KR008 은 이 다섯 축 중 사실상 (2) 의 절반 (euclid + 0.3·softhit) 만 갖고, (1)(3)(4 일부)(5) 는 통째로 비어 있었다—내 KR008 은 정확히 2 위의 "Pool A 단일 멤버"에 해당한다 (2 위 요약 결론).

🔥 내가 떠올렸어야 한 것] 먼저 짚고 갈 대비 하나. OOF 는 내 손안의 작은 검증셋이고, LB 는 전체 테스트셋 약 1 만 개다 (별도 분포). 그래서 어떤 변경이 1cm 경계 샘플을 미세하게 밀어주는 효과는, 표본이 작고 train 분포 안쪽 신호만 보는 OOF 에서는 노이즈에 묻혀 안 보여도, 표본이 크고 별도 분포인 LB 에서는 살아나 보일 수 있다. 이 대비를 깔고 아래를 보자. 나는 단일 Kalman 잔차 GRU 를 튜닝하는 데까지는 했지만, "이 한 모델로 천장을 더 올리자"가 아니라 "이 모델을 한 멤버로 두고 성질 다른 모델을 옆에 세워 블렌드하자"는 발상을 못 했다. 그 발상은 내가 이미 손에 쥐고 있던 관찰에서 나올 수 있었다—KR002(yaw rotation(yaw 회전—마지막 속도 벡터를 항상 +x 축에 정렬하도록 xy 평면을 돌리는 회전 불변 좌표계. 절대좌표로 흩어진 같은 모양의 회전을 같은 패턴으로 보게 해 학습을 쉽게 한다)) 는 OOF +0.0024(ns = not significant, 통계적으로 유의하지 않음 = 측정 노이즈와 구분 안 됨) 인데 LB +0.0060, KR003(Kalman feature, 본질적으로 innovation(칼만 필터에서 관측과 예측의 차이. KR003 이 부산물 피쳐로 넣었으며, 본질적으로 노이즈의 한 측정치다. 나는 이를 '노이즈 추정 피쳐화'로 일반화하지 못한 점을 회고한다)) 는 OOF +0.0004(ns) 인데 LB +0.0036(EXPERIMENTS.md). 위 대비대로, OOF 로는 안 움직이는데 LB 만 오르는 이 현상 (이름하여 CV-LB gap —교차검증 (OOF) 점수는 안 움직이는데 리더보드 (LB) 점수는 오르는 (혹은 그 반대) 괴리. OOF 가 train 분포 내부 신호라 1cm 경계 샘플의 미세 시프트를 못 잡지만 별도 test 분포인 LB 에서는 살아나기 때문. 이 문서의 핵심 진단 단서) 은 곧 "내 단일 모델의 OOF 가 1cm 경계 샘플의 미세 개선을 못 잡아낸다"는 신호였다. 단일 모델 OOF 가 둔감하다면, 답은 그 둔감한 OOF 를 더 쥐어짜는 게 아니라 오차 방향이 다른 모델을 추가해 경계 샘플을 다른 각도에서 한 번 더 밀어 보는 것이었다. 나는 lever 수확이 체감 (+0.0060→+0.0036→+0.0008) 하는 걸 'paradigm 종료 신호'로 읽고 멈췄지만 (KR008), 이 diminishing returns(lever 수확 체감—같은 패러다임 안에서 lever 를 더할수록 lift 가 점점 작아지는 현상 (yaw +0.0060→부산물 +0.0036→aug +0.0008). 나는 이를 '대회 종료'신호로 오독했으나 실제로는 '단일 arch 패러다임'종료 신호였다) 는 실제로는 단일 arch 패러다임이 끝났다는 신호였지 대회가 끝났다는 신호가 아니었다 (참고로 그 마지막 +0.0008 은 noise floor(측정 자체의 잡음 한계. 어떤 변경의 효과가 noise floor 안 (예: LB +0.0008) 이면 통계적으로 효과 유무를 결론 낼 수 없다 (inconclusive). multi-seed 로 noise floor 를 알아야 작은 lift 의 진위를 판단한다) 안쪽이라 사실상 inconclusive 였다) —우승자 다섯 명 전원이 바로 그 지점에서 "단일 → 다양성 블렌드"로 갈아탔다.

💡 내가 떠올렸어야 한 것—지표 정렬) 나는 손실에 softhit 를 0.3 가중으로 곱해지는 선에서 멈췄지만 (주항은 euclidean loss(euclid —예측과 정답 사이의 유클리드 거리를 직접 줄이는 손실. 내 KR008 의 주항 (euclid + 0.3·softhit) 으로, ‘평균 거리 최소화’가 지배해 경계 직접 공략이 약했다)), 우승자들은 거리 손실을 보조로 내리고 hit 를 주력으로 끌어올렸다 (1 위는 hit 손실 가중 2.0×; 3·4 위는 hit 를 1 순위 항으로 두고 그 경계 날카로움 상수까지 외부 자동탐색으로 정밀 튜닝). 더 결정적으로, early-stop 을 val loss 가 아니라 val hit-rate 로 걸었다 (2 위 Cell 9, 4 위 line 524, 3 위 cell 6113). 이 발상은 “내 지표는 평균 거리가 아니라 1cm 이진 hit”라는 문제 정의 그 자체를 손실·검증 양쪽에 끝까지 관찰하면 나오는 것이었는데, 나는 지표를 ‘평가용’으로만 쓰고 ‘최적화 대상’으로는 절반만 썼다. 앞 blockquote 의 sigmoid 직관 (경계에서 기울기가 최대 → 경계 샘플에 보정 집중) 이 왜 hit 손실이 점수를 올리냐’의 답이다. §1 의 거리분포 (평균 0.22cm·97.4% 1cm 이내) 가 말해주듯, 이 문제의 승부처는 평균을 줄이는 것이 아니라 경계의 hit/miss 를 뒤집는 것이었다.

2. 내 접근법 정리 (파이프라인 순서)

이 섹션은 내가 실제로 걸어온 길을, 데이터가 들어와 점수가 나오기까지의 순서로 다시 간다. 기능 목록이 아니라 “11 스텝짜리 짧은 궤적이 어떻게 +80ms 위치 하나로 바뀌고, 그 정확도가 왜 단계마다 올랐는가”의 흐름이다. 마지막엔 내가 부딪힌 벽과, 시도했다 죽은 길들을 정직하게 적는다. (참고: 이하 등수는 분석 대상 0.70+ 5 인의 score 순위다. 4 위·5 위의 정확한 DACON private 순위는 비공개다.)

한 가지 용어를 먼저 짚아둔다. 이 섹션에서 자주 나오는 lane(레인—내가 한 실험 계열, 즉 같은 뼈대를 공유하며 번호를 이어 붙인 한 줄기의 실험 묶음)이라는 말은 “내 메인 엔진 실험 줄기”를 가리킨다. 예컨대 KR001~KR008 은 전부 하나의 KR lane(Kalman 잔차 GRU 계열) 이다.

먼저 우리가 무엇을 맞추는 게임인지 못 박자.

항목	내용
입력	모기 궤적의 마지막 11 스텝 (40ms 간격) × 3D 좌표 = (11, 3) 배열
출력	그 직후 +80ms 시점의 위치 (x, y, z) 하나
지표	hit@1cm —예측이 정답과 1cm(0.01m) 이내면 1, 아니면 0. 즉 거리를 “얼마나” 줄이느냐가 아니라 “1cm 선을 넘었느냐”의 이진 판정. (출처: EXPERIMENTS.md L3, plan-a-001)

이 지표의 성격이 이 글 전체의 복선이다. 1cm 가 절벽이다. 0.9cm 는 만점, 1.1cm 는 빵점. 평균 거리를 줄이는 게 아니라 1cm 경계에 걸친 sample 들을 안쪽으로 밀어넣는 게 점수다. 이 사실을 내가 끝까지 충분히 무겁게 다루지 못한 것이 4·5 섹션에서 우승자들과 갈린 지점이다.

2.1 F0 베이스라인—“직전 속도로 그냥 직진”(OOF 0.6320, LB ~0.60)

왜 이 단계가 필요한가. 무엇이든 출발선이 있어야 “내 모델이 진짜 뭔가 배웠는지”를 잴 수 있다. 가장 멍청하지만 가장 정직한 출발선은 물리 직관 그 자체다.

무엇을 하는가. F0(내 베이스라인 이름) 은 2 점 선형 외삽이다. 마지막 위치에 “마지막 한 스텝의 변위”를 그대로 한 번 더 더한다.

$$F0_pred = last + (last - prev)$$

즉 “방금 움직인 만큼 한 번 더 움직일 것”이라는, 등속 (속도 일정) 가정. (출처: EXPERIMENTS.md L4, plan-001 linear-2pt)

그래서 점수가 왜 이렇게 나오는가. OOF(out-of-fold, 학습에 안 쓴 데이터로 잦 정직한 점수) hit@1cm = 0.6320, LB(리더보드, 진짜 채점) $\approx$ 0.60. 놀라운 건 공짜로 63% 가 맞다는 것이다. 모기 께적의 다수는 짧은 80ms 동안 거의 직진이라, 등속 외삽만으로도 1cm 안에 들어온다. 이게 의미하는 바: 나머지 $\sim$ 37% 는 “직진이 깨지는” sample — 급선회·가속·노이즈가 낀 께적이다. 앞으로 모든 점수 상승은 이 37% 를 얼마나 회수하느냐의 싸움이고, 이 사실이 뒤에서 우승자들의 “급선회 oversampling” 트릭을 이해하는 열쇠가 된다.

한 가지 메모: 나는 등속만 썼지만, F0 를 “등속 + 등가속”으로 한 줄만 늘렸어도 ($last + 2 \cdot (last - prev)$) 더 나은 base 가 됐을 수 있다. 두 식의 차이는 물리적으로 분명하다. $last + (last - prev)$ 는 직진 한 스텝의 속도로 그대로 직진하라는 등속 가정이다. 반면 $last + 2 \cdot (last - prev)$ 는 같은 변위를 2 배 더한다—우리가 맞히려는 시점이 +80ms 인데 한 스텝이 40ms 이므로, 정확히 두 스텝 앞이다. 즉 “방금의 변위가 앞으로 두 스텝 동안 이어진다”고 본 것이라, 짧게나마 속도가 유지·증가하는 (가속 항이 살아 있는) 께적을 더 잘 짚는다. 실제로 1 위는 정확히 이 $last + 2 \cdot (last - prev)$ 를 공통 base 로 쓴다 (뒤에서 cv_1step 이라는 이름으로 §3·§4·6.2 에 계속 나온다—같은 식이다). 출발선 자체의 품질 차이는 여기서 이미 시작됐다.

2.2 plan-004 — 공개 노트북 framework 이식 (LB 0.6806, 내 첫 큰 도약)

왜 이 단계가 필요한가. F0 는 하나의 답만 낸다. 그런데 어떤 께적은 직진, 어떤 건 좌회전, 어떤 건 감속이다. 하나의 공식으로 전부 맞추는 건 무리다. “여러 후보를 만들고 그중 고른다”는 발상이 필요하다.

무엇을 하는가. 공개 PB 0.6822 노트북 (내 plan-004 framework 원본) 의 framework 를 그대로 이식했다. 핵심 두 부품:

1. 27-candidate selector — 한 께적 하나에 대해, 서로 다른 단순 운동 가정으로 27 개의 후보 위치를 만든다. 예컨대 (등속·등가속·감속·좌회전 지속·우회전 지속...) 같은 여러 외삽 규칙을 각기 다른 시간원도/스무딩 정도와 조합하면 27 개의 “있을 법한 +80ms 위치”가 나온다. selector 는 이 27 개 중 하나만 딱 고르는 게 아니다. 각 후보가 얼마나 그럴듯한지 점수를 매긴 뒤, 그 점수를 가중치로 27 개를 평균한다—이게 “soft(부드럽게) 평균 가중”의 뜻이다 (딱 하나를 hard 하게 고르는 게 아니라, 그럴듯한 후보일수록 무게를 더 실어 섞는다). 즉 범주를 직접 분류하는 게 아니라, 후보 풀을 만들어 가중평균으로 합치는 구조다.
2. boundary corrector — 그렇게 합친 후보를 작게 보정해 1cm 경계 쪽으로 당긴다.

(출처: EXPERIMENTS.md L33 plan-004, plan-005 diagnostic)

그래서 점수가 왜 오르는가. LB 0.6806. linear(F0) 대비 +0.08. 내 첫 큰 도약이고, 이 문서를 통틀어 가장 큰 단일 점수 도약이다. 왜 이렇게 크게 올랐나—F0 가 못 잡던 “직진이 깨지는 37%”의 상당수를, 27 개 후보 중 맞는 모양의 후보가 하나라도 있으면 회수하기 때문이다 (좌회전 께적이면 좌회전 후보에 무게가 실린다). 후속 진단 (plan-005) 에서 밝혀진 더 냉정한 사실: framework 의 95% 는 장식이고 진짜 엔진은 “27 개 후보 + physics_-bias(후보들에 물리적 그럴듯함을 더 없는 가중 항) + soft averaging(위에서 푼 그럴듯함-가중 평균)”이었다. 즉 도약의 정체는 정교한 구조가 아니라 후보 다양성—“여러 모양을 미리 만들어두고 섞는다”는 것 하나였다.

이 “다양성이 carrier(점수를 실어 나르는 진짜 운반체)”라는 교훈은 4 섹션에서 우승자들의 ensemble(앙상블—여러 모델의 예측을 평균/가중평균해 하나의 최종 예측으로 합치는 기법. 성질이 다른 모델을 섞을수록 효과가 커진다) 을 만나면 정확히 한 단계 위로 반복된다. 지금은 한 모델 안에서 후보를 다양화했지만, 우승자는 서로 다른 모델 자체를 다양화한다. 후보 다양성 → 모델 다양성으로.

2.3 Kalman 잔차 GRU lane — 내 메인 엔진 (KR001 → KR008, LB 0.6862)

왜 이 단계가 필요한가. plan-004 는 후보를 고르는 틀이었다. 다음 질문은 “물리로 대충 예측해두고, 그 예측이 틀린 만큼 (잔차) 을 신경망이 따로 배우게 하면 어떨까?”이다. 절대 위치를 처음부터 맞추는 것보다, 좋은 물리 base 위에

작은 보정만 배우는 게 훨씬 쉽다 (배워야 할 양이 작으니 분산이 작다).

전체 구조 (KR001, 출처: plan-a-001, 원본 = 내 Kalman-residual GRU lane 의 원본 공개 노트북 (LB 0.6780) 재현):

1. Kalman 필터로 +80ms 위치를 물리 예측 (등속 칼만, 축별 독립)
2. 정답 - Kalman 예측 = "잔차" 를 계산
3. GRU(1-layer, hidden=64) + scalar MLP 가 이 잔차만 학습
4. 출력은 $\tanh \times 2\text{cm}$ 로 clip → 보정량을 $\pm 2\text{cm}$ 로 물리적으로 제한
5. 최종 = Kalman 예측 + GRU가 낸 잔차
 - 손실: euclid + 0.3·softhit (유클리드 거리 + 1cm 경계를 부드럽게 근사한 hit 손실)
 - 메인 head + auxiliary head(보조 head —메인 예측과 별개로 F/W 같은 보조 타깃을 함께 맞춰 학습을 돕는 부가 출력)
 - single-phase(한 번에 학습), 2 config $\times$ 5 fold $\times$ 3 seed = 30 개 모델을 OOF 에서 평균
 - TTA 없음, oversample 없음, augmentation 없음 ← 이 셋이 5 섹션의 핵심 결손이다

그래서 점수가 왜 오르는가. KR001 OOF 0.6639 —F0 대비 +0.0319. 큰 도약이다. 이유는 위 “왜”에서 말한 그대로: 물리 base(Kalman) 가 직진 부분을 깔아주고, GRU 는 깨지는 부분의 잔차만 집중 학습하니 학습 난이도가 낮다. 흥미롭게도 나중에 베이스를 Kalman 대신 F0 로 바꿔도 (c-001 FR001, OOF 0.6622) 거의 같은 lift 가 나왔다—즉 “lift 는 base 품질이 아니라 GRU 가 잔차를 배운다는 구조 자체에서 온다”(EXPERIMENTS.md L66). 이것도 4 섹션 복선이다. 우승자들도 전부 이 “잔차 학습” 패러다임 위에 서 있다.

여기서부터가 이 lane 의 진짜 이야기다. 나는 KR001 위에 작은 lever 들을 하나씩 얹었고, 그때 CV(OOF) 와 LB 가 따로 노는 현상을 발견한다.

단계	무엇을 추가했나	OOF Δ	LB Δ	무슨 일이 일어났나
KR002	입력 yaw 회전 (속도 +x 축 정렬)	+0.0024 (의미없음)	+0.0060	CV-LB 괴리 1 차 확증
KR003	Kalman 부산물 feature	+0.0004 (의미없음)	+0.0036	괴리 2 차
KR008	반사 + 노이즈 augmentation (train-only)	+0.0004	+0.0008	noise floor 내, inconclusive

(출처: EXPERIMENTS.md L61-63, plan-a-001/002/003.results.md)

KR002 의 yaw 회전부터 풀어보자. “왜 필요한가”—같은 좌회전이라도 모기가 동쪽을 보고 있을 때와 북쪽을 보고 있을 때, 절대좌표로는 완전히 다른 숫자다. 그런데 “진행 방향 기준으로 왼쪽으로 꺾는다”는 본질은 같다. 그래서 마지막 속도 방향을 항상 +x 축으로 돌려놓으면 (회전 불변 좌표계) 신경망이 같은 모양을 같은 패턴으로 본다. 학습이 쉬워진다.

문제는 점수다. OOF 로는 +0.0024 로 거의 안 올랐는데 (통계적으로 무의미), LB 로는 +0.0060 올랐다. 이게 CV-LB 괴리 (cross-validation 점수와 리더보드 점수가 따로 노는 것) 의 첫 확증이다. KR003(Kalman 부산물 feature) 에서 또 반복된다—OOF +0.0004(무의미), LB +0.0036. 두 번 연속이면 우연이 아니다.

이 괴리를 어떻게 읽었어야 했나가 중요하다. 내 OOF 측정은 hit@1cm 이라는 이진 지표라 분산이 크고, 특히 1cm 경계에 걸친 sample 들에서 둔감하다. yaw 회전이 만드는 개선은 바로 그 경계 sample 들의 미세한 위치 시프트인데, 내 작은 OOF fold 로는 그 시프트가 noise 에 묻힌다. 반면 LB 는 10000 개 전체 테스트셋이라 그 미세 시프트가 통계적으로 살아난다. 즉 “OOF 가 안 움직여도 LB 는 움직일 수 있다”가 이 대회 구조적 진실이었다.

💡 내가 떠올렸어야 한 것] 여기서 내가 망설인 지점. 나는 KR002·KR003 을 보며 “OOF-neutral 인데 버릴까 말까”를 망설였다 (EXPERIMENTS.md L62 “OOF-neutral 으로 폐기 안 한 plan 설계 보상”). 다행히 안 버렸지만, 이 괴리를 기회로 적극 읽지는 못했다. 만약 “1cm 경계 sample 이 carrier 다 → OOF 는 둔감하다 → 그렇

다면 경계 sample 을 직접 공략하는 lever(경계 가중 손실, 급선회 oversample, hit-rate 기준 early-stop) 를 쏘아보자”로 전환했어야 했다. 우승자들이 한 게 정확히 그것이다. 이 복선은 4·5 섹션에서 회수된다.

KR008 은 마지막 시도였다. 반사 + 노이즈 augmentation 을 얻었지만 LB +0.0008 —noise floor(측정 잡음) 안 이라 효과가 있는지조차 결론 못 냈다. 그리고 여기서 멈춰야 할 신호가 명확히 보였다:

lever 수 확: yaw +0.0060 → 부산물 +0.0036 → aug +0.0008
(단조 감소, 점점 작아짐)

lever 수확 체감 (diminishing returns) = paradigm 종료 신호. 같은 패러다임 (단일 GRU + 잔차) 안에서 짜낼 수 있는 좁이 말랐다는 뜻. 내 최고점은 KR008 LB 0.6862 / OOF 0.6671 에서 멈췄다. 더 짜내는 게 아니라 패러다임을 바꿔야 다음 절벽을 넘는다는 신호였는데, 나는 한참 더 같은 우물을 팠다 (아래 2.5 실패 목록).

2.4 결가지로 검증된 것—plan-031 training procedure (+0.0103 OOF)

내 메인 lane(KR) 과는 별개로, 또 하나의 거대 lever 를 따로 확인했다. plan-031: 공개 노트북의 training procedure(학습 절차—모델 구조는 그대로 두고 어떻게 학습시키느냐만 바꾸는 부분. 핵심은 데이터를 미리 한 번 훑어 모델을 예열한 뒤 본학습으로 미세조정하는 여러 단계로 나눈 학습 방식이다) 를 이식하니 OOF +0.0103 가 났다 (EXPERIMENTS.md L59). 이 lift 는 모델 구조를 하나도 안 바꾸고 학습 절차만 바꿔 얻은 것이라, 단일 lever 로는 매우 큰 편이다.

왜 이게 중요한가. “같은 모델이라도 어떻게 학습시키느냐가 carrier”라는 진단 (EXPERIMENTS.md L24, L58 “main carrier = training procedure”) 의 직접 검증이기 때문이다. 다만 이건 내 KR lane 에서 쟁 게 아니라, 따로 굴린 별개 모델 (GRU 에 attention 을 얹은 구조) 위에서 측정한 값이다. 그래서 base 가 다르고, 내 KR008 에 이 학습 절차를 그대로 합쳐 점수를 더하는 일은 끝내 못 했다—“좋은 절차가 있다”는 걸 확인만 하고 내 메인 엔진에 이식은 못 한, 절반의 수확이다.

여기서 한 가지 다리를 박아둔다. 이“여러 단계로 나눠 사전학습 후 미세조정하는”학습 절차는, §4-4 (4) 에서 다들 우승자들의 커리큘럼 사전학습·hit-rate 기준 early-stop 과 정확히 같은 갈래다. 즉 내가 결가지에서“큰 lever 다”라고 확인만 하고 메인에 못 붙인 그 학습 절차를, 우승자들은 처음부터 메인 학습의 뼈대로 삼았다. 이 미합류가 5 섹션에서 비교될 지점이다.

2.5 내가 시도했다 죽은 것들 (정직하게)

KR008 에서 paradigm 종료 신호를 보고도, 나는“단일 arch + 잔차”우물 주변을 계속 팠다. 아래는 전부 sub-threshold / neutral / KILL 로 끝난 시도들이다. 하나도 내 0.6862 를 넘지 못했다.

아래 표의 개별 시도 이름들 (Multi-hypothesis, SetTransformer, voxel CE, codebook, energy-based 등) 은 지금 하나도 몰라도 된다. 요점은 딱 하나다—이 시도들은 전부“한 모델 안에서”무언가 (구조·출력 형식·손실·좌표계) 를 바꾼 변주였고, “여러 다른 모델을 섞는다”는 축은 여기 한 줄도 없다. 표는 그 사실을 보여주려고 둔 것이니, 용어에 멈추지 말고 맨 오른쪽“죽은 이유”가 전부 같은 우물 안 이야기라는 것만 느끼고 지나가면 된다.

시도	plan	결과	죽은 이유
Multi-hypothesis (2-head, 여러 답 후보)	a-004	KILL	oracle headroom +0.003 << +0.020 gate. 단일 GRU 가 이미 conditional 최적, head 가 분화 안 됨

시도	plan	결과	죽은 이유
single-stack arch ablation (SetTrans/PathSig/MoLE/GRU- attn)	018	4/4 FAIL	best 가 baseline 대비 +0.0003. “구조만 바꾸기”lever 자체가 falsify 됨
Neural ODE (학습형 물리 적분)	d-001	OOF 0.6330	F0 와 동률 (+0.0010, p=0.79). fold0 peak 0.6663 이 final-epoch 에 0.6307 로 퇴행 —overfit
yaw-frame anchor (회전 좌표계 + anchor selector)	b-001	양 arm regress	“frame 문제가 carrier”가설 기각
1080D LGBM row-expand	025	mode collapse	후보별 행 확장이 균일 분포로 붕 괴 → soft-mean $\approx$ F0
GRU-attention	029/030	regress	attention 학습은 정상인데 framework 가 F0 floor 아래
voxel CE (3D 격자 분류 7 ³)	017	-0.0121	격자 분류가 회귀보다 나쁨
codebook (앵커 분류)	012/014	ceiling 0.6425	corrector 패러다임 천장
energy-based (EBIP+ICNN)	019	marginal only	gate 미달

(출처: EXPERIMENTS.md L47, L48, L53, L57-58, L64-67 및 각 plan results)

이 목록의 공통 패턴이 보인다: 나는 거의 전부“단일 모델 안에서 무엇을 바꾸나”의 변주였다. arch 를 바꾸고 (018), 출력 형식을 바꾸고 (017 voxel, 012 codebook), 손실의 종류를 energy-based 로 바꾸고 (019), 입력 좌표계를 바꿨다 (b-001). 그런데 “여러 다른 모델을 섞는다”는 축은 한 번도 본격적으로 안 건드렸다. multi-hypothesis(a-004) 가 가장 근접했지만 그건 한 모델 안의 여러 head 였지 서로 다른 inductive bias 를 가진 별개 모델들의 앙상블이 아니었다.

2.6 내가 끝내 못 넘은 벽 (4.5 섹션으로 가는 다리)

정리하면, 내 최종 형태는 이렇게 요약된다—그리고 이 요약의 각 항목이 우승자들과 정확히 같린 지점이다.

내 KR008 의 특성	한 줄 진단
단일 arch (Kalman 잔차 GRU 한 종류)	모델 다양성 = 0. 가장 큰 결손
MSE 계열 단일 손실 (euclid + 0.3·softthit)	1cm 경계를 직접·강하게 공략 안 함
TTA 없음	inference 시 대칭성 같은 공짜 정보 미활용
oversample 없음	“직진 깨지는 37%”(급선회 tail) 를 더 보지 않음
augmentation 없음	학습 데이터 다양성 부족
CV-LB 괴리를 망설임	“OOF-neutral 이니 버릴까”에서 멈춤—괴리를 무기로 못 씀

내 최고 LB 0.6862 / OOF 0.6671 과 1 위 사이의 격차는 다음과 같다 (측정된 단언 가능한 수치만):

- 1 위 대비 —0.0173 (LB 0.703 vs 0.6862)
- 5 위 (0.700) 대비 —0.0138
- 재현된 1 위 솔루션 기준으로는 KR008 대비 +0.0168 lift 가 측정됨 (plan-w-001.results.md §3.4)

여기서 가장 중요한 사실 하나—이 +0.0168 이 “어디서”왔는지를 보면, 내가 무엇을 못 봤는지가 드러난다. 1 위와 내 KR008 의 예측 좌표를 직접 비교하니 (plan-w-001.results.md §3.3):

두 모델 예측 거리	비율
평균 거리	0.22cm
1cm 이내	97.4%
P95 거리	0.64cm

즉 1 위와 내 답은 평균 0.22cm 밖에 안 떨어져 있다. 97.4% 는 거의 같은 위치를 찍는다. 그런데 LB 는 0.0168 차이가 난다. 이게 가능한 유일한 이유: 1cm 경계에 걸친 소수 sample 들이, 그 0.22cm 짜리 미세 시프트로 hit↔miss 를 갈았기 때문이다. carrier 는 큰 구조 변화가 아니라 경계에서의 작은 좌표 정확도였다.

이건 내가 KR002/KR003 에서 본 CV-LB 괴리와 정확히 같은 현상이다. 그때“OOF 는 안 움직이는데 LB 는 움직인다”고 당황했던 그 1cm 경계 민감도가, 우승과 나를 가른 바로 그 메커니즘이었다. 나는 이 신호를 두 번이나 손에 쥐고도 경계 공략을 메인 전략으로 승격시키지 못했다.

4 섹션 복선 (1 위가 한 것): 1 위 솔루션은 $\text{AttnGRU} \times 10 + \text{Neural ODE} \times 10 + \text{HyperPhysics} \times 10 = 30$ 모델 등 가중 블렌드다 (rank1 노트북). 내가 한 번도 본격적으로 안 건드린 “서로 다른 inductive bias 를 섞어 오차를 탈상관”이 정확히 이것이다. 게다가 그 위에 Soft R-Hit loss(1cm hit 을 직접 최적화), Y-flip TTA(대칭 입력 평균), θ -가중 oversampling(급선회 최대 5 배 가중) —내 표의 “한 줄 진단”결손 항목과 일대일로 대응한다. 단, 이 6 개 component 의 개별 ΔLB 는 아직 측정 안 됐다 (ablation plan w-2~7 미실행). 측정된 건 전체 격차 +0.0168 과 위 거리분포뿐이니, 4 섹션에서는 “어느 게 얼마”가 아니라 “내가 못 한 개념적 도약이 무엇인지”로 다룬다. (참고: 위 HyperPhysics 물리모델은 그 계보의 출발점인 9 위 솔루션이 원작자다.)

5 섹션 복선 (다른 우승자들의 패턴): 신규 우승자 4 명을 보면, 내 결손 항목들이 반복해서 나타난다 (전부 추출된 코드 근거). 공통점: 넷 다 잔차 학습 (나와 같음) + 물리 inductive bias 위에서 있고, 급선회 oversample·hit 직접 최적화 손실·(대부분) hit 기준 early-stop 을 쌓는다. 차이점은 다음과 같다. - 2 위 (Private 0.7031): GRU + Neural-ODE + Frenet control-head + 회전물리, 4 개 직교 풀 앙상블. 내 KR008 은 그중 “Pool A 단일 멤버”에 해당한다 (손실 계수 $\text{euclid} + 0.3 \text{softhit}$ 까지 동일). 격차 = 다양성·블렌드·증강·oversample. - 3 위 (Private 0.7019): 물리 NN 을 주모델 (OOF 0.6739) 로, Kalman-GRU 는 보조 (OOF 0.6581). θ -기반 WeightedRandomSampler oversample(급커브 5 배) + SlidingWindow 증강. - 4 위 (Private 0.7011): 물리코어 위 잔차 GRU(zero-init) + theta oversample + val hit-rate 기준 early-stop(MSE 아님) + 이분산 NLL. - 5 위 (Private 0.700): GRU+Transformer 물리 디코더 (좌표 대신 물리 6 계수 회귀) + 커리큘럼 사전학습 + 경계 가중 LGBM 잔차 보정.

즉 내가 KR lane 에서 발판은 똑같이 밟았는데 (잔차 GRU + softhit), 그 위에 쌓는 “1cm 경계·급선회 tail 공략”도구 일습을 통째로 비워둔 게 -0.0138~-0.0173 의 정체다. 5 섹션에서 이걸 우승자별로 해부한다.

3. 우승자 공통 패턴 (0.70+ 5 명에서 반복되는 것)

이 섹션을 읽기 전에 한 문장으로: 0.70 을 넘긴 다섯 명은 서로 다른 사람인데도, 코드를 펼쳐 놓고 보면 같은 여섯 개의 결정을 거의 똑같이 내렸다. 내 (KR008) 가 그중 몇 개를 안 했거나, 했더라도 절반만 했다. 이 섹션은 “그 여섯 개가 각각 왜 점수를 올리는가”를, 데이터가 들어와서 점수가 나오는 순서대로 따라간다.

먼저 다섯 명이 무엇을 공유하는지 한눈에 (이하 등수는 0.70+ 5 인의 score 순이다—4·5 위의 정확한 DACon private 순위는 비공개):

우승자	LB(Private)	한 줄 정체
1 위	0.7035 (재현 0.703)	GRU + Neural-ODE + HyperPhysics 30 모델 등가중 blend
2 위	0.7031	직교 multi-pool(4 패러다임) ensemble ~40 멤버
3 위	0.7019	HyperPhysics 주모델 + Kalman-GRU 보조, OOF weighted blend
4 위	0.7011	physics-core + 잔차 GRU, K-fold
5 위	0.700	GRU+Transformer physics decoder + LightGBM 후보정
나 (KR008)	0.6862 (OOF 0.6671)	단일 Kalman 잔차 GRU

내 격차는 1 위 대비 -0.0173 , 5 위 (0.700) 대비 -0.0138 . 작아 보이지만, 이 지표가 “정답과 $\leq 1\text{cm}$ 이면 1 점, 아니면 0 점”인 $\text{hit}@1\text{cm}$ 라서, 이 $0.013\sim 0.017$ 은 “예측을 평균 몇 mm 더 정답 쪽으로 밀었느냐”의 문제다. 실제로 1 위와 내 KR008 의 예측 좌표는 평균 0.22cm 밖에 안 떨어져 있고, 97.4% 가 서로 1cm 이내 (`plan-w-001.results.md §3.3`) 다. 그런데 LB 는 0.0168 벌어진다. 즉 1cm 경계에 걸린 소수의 샘플을 누가 안쪽으로 밀어 넣었느냐가 전부다. 아래 여섯 축은 전부 “그 경계 샘플을 밀어 넣는 서로 다른 손잡이”다.

(a) 좌표를 직접 예측하지 않는다—물리 base 를 깔고 그 위의 잔차/계수만 학습

왜 이 단계가 필요한가. 모기의 $+80\text{ms}$ 위치는 대부분 “지금 속도로 그냥 직진”하면 거의 맞는다. 신경망에게 절대 좌표 (x, y, z) 를 통째로 맞히라고 하면, 모델은 “대충 직진”이라는 쉬운 99% 를 학습하느라 용량을 다 쓰고, 정작 점수를 가르는 “꺾이는 순간의 작은 보정”은 못 배운다. 그래서 다섯 명 전원이 쉬운 부분은 공식으로 미리 깔아두고 (=baseline), 신경망은 그 baseline 이 틀린 만큼 (=residual) 만 배우게 한다.

무엇을 하는가—공통점과 차이점. 다섯 명 모두 공식으로 base 예측을 깔고, 신경망은 그 base 의 잔차 (또는 계수) 만 yaw-local 좌표계에서 배운다는 골격이 같다. 차이는 base 의 정교함이다—1 위는 $\text{cv_1step} = \text{last} + 2 \cdot (\text{last} - \text{prev})$ 등속 외삽 (Cell 7) 으로 가장 단순하게 깔고, 2·3 위는 축별 등속 Kalman filter (2 위 Cell 4 / 3 위 Cell 6194) 를 base 로 쓴다. 4 위는 학습형 physics-core (EMA 등속 + 등가속 + Rodrigues rotation) 를 base 로 두고 그 위 zero-init GRU residual 을 엮는다. 5 위는 한 발 더 나가, 잔차조차 좌표로 두지 않고 물리 운동방정식의 6 개 계수를 회귀한 뒤 decoder 가 좌표를 복원한다.

여기서 중요한 변형 두 가지가 보인다. (1) 출력에 output bound 를 건다: 2·3 위는 residual head 출력을 $\tanh \times 2\text{cm}$ 로 묶어, 신경망이 base 를 2cm 이상 밀지 못하게 한다 (2 위 Cell 8 / 3 위 Cell 6291). base 가 거의 맞으니 보정은 작아야 하고, outlier 폭주를 구조적으로 막는다. (2) 5 위는 좌표가 아니라 “접선 방향으로 얼마, 법선 (구심) 방향으로 얼마, jerk (저크—가속도의 변화율. 궤적의 급격한 변화를 포착하는 운동학 피쳐로, 여기서 물리 계수의 한 축으로 6 계수 분해에 들어간다) 얼마” 같은 물리 계수를 출력하는 physics decoder 를 쓰고, 각 head 에 활성화함수로 물리적 범위를 강제한다 ($d1s = \text{softplus} \geq 0$, $\text{perps} = \tanh \times 8$, $ts \in [0.6, 1.4]$, Cell L246). 비물리적인 해 (예: 음의 전진 거리) 를 애초에 못 내게 한다.

그래서 점수가 왜 오르는가. 학습 문제가 “절대좌표 맞히기 (분산 큼)”에서 “작은 보정량 맞히기 (분산 작음)”로 바뀐다. 같은 데이터·같은 모델이라도 타깃 분산이 작으면 학습이 안정되고, 경계 샘플의 작은 시프트를 더 정밀하게 만든다—그게 곧 $\text{hit}@1\text{cm}$ 이득이다.

💡 내가 떠올렸어야 한 것] 나는 “Kalman 잔차를 GRU 로 학습”까지는 했다 (KR001). 즉 residual 패러다임 자체는 맞게 짰었다. 하지만 나는 residual = 출력 표현을 하나로만 봤다. 다섯 명 중 5 위는 “잔차조차 좌표로 두지 말고, 물리적으로 의미 있는 계수 (접선/법선/jerk) 로 바꾸면 head 마다 활성화함수로 비물리해를 차단할 수 있다”는 한 걸음을 더 갔다. 이 발상은 “내 residual head 가 가끔 말도 안 되는 큰 보정을 내서 hit 를 깨는구나”를 관찰했으면 나왔을 것이다—그 관찰을 하려면 잔차의 분포를 그려봐야 했는데, 나는 OOF 숫자만 봤지 잔차가 어떤 방향으로 얼마나 틀리는지 시각화하지 않았다.

(b) 물리 모델 prior + 신경망 보정—회전 동역학을 신경망에 “주입”한다

왜 이 단계가 필요한가. (a) 의 residual 학습은 base 가 등속 직진일 때 가장 잘 통한다. 그런데 점수를 깨먹는 샘플은 정확히 모기가 꺾는 순간이다. 등속 base 는 회전을 전혀 모르니 잔차가 커지고, 잔차가 커지면 신경망도 그만큼 헤맨다. 해법은 base 자체를 더 똑똑하게—회전 (뱅킹 턴) 을 아는 물리 모델로 만드는 것이다.

무엇을 하는가. 세 명 (1 위의 HyperPhysics 파트, 3 위, 4 위) 이 거의 동일한 gray-box physics 신경망을 쓴다. gray-box (회색상자) = 내부가 물리 공식으로 짜여 있고, 그 공식의 계수만 신경망이 채우는 구조다. 핵심 부품이 셋

모두에서 반복된다:

- Rodrigues rotation: 각속도 ω (오메가—단위시간당 회전량) 로 속도벡터를 매 스텝 조금씩 돌려 곡선 궤적 (뱅킹 턴) 을 만든다 (rodrigues_rotate, 1 위 Cell 16 / 3 위 cell 6070 / 4 위 line 459). 그림으로 잡으면 이렇다—등속 외삽은 코너에서 직선으로 그대로 빠져나가 정답보다 바깥으로 튜다. 속도벡터를 ω 만큼 매 스텝 돌려주면 예측 궤적이 실제 곡선을 따라 휘어, 코너 안쪽으로 들어온다. 즉 “직진 외삽이 밖으로 흘리는 만큼”을 회전으로 되감는 부품이다.
- PriorBiasedLinear: 마지막 층을 weight=0 으로 초기화하고 물리 prior 를 buffer(학습 안 되는 고정 텐서) 로 더한다. 이게 왜 “학습 시작 = 순수 물리”가 되냐면—마지막 층 가중치가 0 이면 신경망이 그 앞에서 무엇을 계산해 내든 0 을 곱해 0 이 되고 (0 을 곱하면 0), 출력에는 buffer 에 넣어둔 물리식 값만 그대로 남는다. 학습이 진행되면 그 가중치가 0 에서 조금씩 자라, 물리식 위에 데이터 보정을 엮는다 (1 위 Cell 16 / 세 명 공통).
- θ /speed gating: turn angle(θ) 와 속력이 임계값을 넘을 때만 회전을 켜다 (theta_gate $\times$ speed_gate, 1 위 Cell 16, $\theta_{thr}=1.087618$). → 직진 구간에서 괜히 회전 보정이 새어 들어와 망치는 걸 막는 다.
- heteroscedastic NLL(이분산 음의로그우도—직관부터): 모델이 각 샘플마다 답뿐 아니라 그 답을 얼마나 자신없어 하는지 (불확실성) 도 함께 내놓게 하고, 자신없다고 스스로 표시한 샘플은 틀려도 덜 혼내는 학습법 이다. 메커니즘은—손실 식이 그 샘플의 오차를 모델이 내놓은 분산으로 나누는 형태라, 분산을 크게 (= 자신없음) 찍은 샘플은 같은 크기로 틀려도 벌점이 작아진다. 결과적으로 모델이 노이즈 심한 애매한 샘플에 억지로 끌려가지 않고, 깨끗한 샘플에 집중한다. (기호 보조: log_var = 분산의 로그값을 출력 head 로 내보 낸 것. NLL = 그 분산으로 오차를 나눠 만든 손실. 이름은 몰라도 “자신없는 샘플은 덜 혼낸다”만 잡으면 된 다.) —1 위 diffusion_net / 3 위 cell 6093 / 4 위 line 476. 참고로 이건 어려운 샘플을 더 많이 보여주는 oversample 과는 정반대 방향의 장치다 (이쪽은 애매한 샘플의 영향을 줄인다).

4 위는 여기에 잔차 GRU 의 마지막 Linear 도 zero-init 해서, “학습 초기 = 순수 물리, GRU 보정 = 0”에서 출발하게 한다 (line 316). (a) 와 (b) 가 한 모델 안에서 합쳐진 형태다.

그래서 점수가 왜 오르는가. 물리 prior 에서 출발하면 (1) 학습 초반부터 base 가 이미 0.6 대를 찍고 있어 발산하지 않고, (2) 데이터가 적은 급선회 영역에서도 물리 공식이 합리적 외삽을 해주며, (3) gating 덕분에 직진 다수 샘플은 건드리지 않는다. 3 위의 측정치가 이걸 뒷받침한다—물리 NN 단독 OOF 0.6739 인데, 같은 사람의 Kalman-GRU 는 0.6581(cell 6477/6533). 약 0.016 차이가 “물리 prior 를 가졌느냐”에서 온다 (단, 이건 3 위 내부 OOF 비교이지 LB 분해는 아님).

[💡 내가 떠올렸어야 한 것] 내 KR008 은 “순수 데이터 GRU + Kalman 잔차”였다—base 는 등속 Kalman 뿐, 회전을 아는 부품이 없었다. 나는 Neural ODE(d-001) 와 fixed-physics(plan-020) 를 시도했다가 둘 다 실패하고 “물리는 안 통한다”고 결론 냈다. 하지만 다섯 명이 쓴 건 고정 물리도, 순수 신경망도 아닌 gray-box(물리 골격 + 학습 계수 + gating) 였다. 내 d-001 NODE 가 F0 동률 (0.6330) 로 끝난 건 “물리가 무용”이어서가 아니라 “물리를 언제 켜지 (θ gating) 와 어디서 출발할지 (PriorBiasedLinear) 를 안 쫓기”때문일 수 있다. 이 발상은 “내 ODE 가 직진 샘플에서 오히려 등속보다 나쁘다”를 봤으면—즉 실패한 샘플이 직진인지 선회인지 쪼개봤으면—“회전을 직진에서 끄자”는 gating 으로 자연스럽게 이어졌을 것이다.

(c) 서로 직교하는 다양성을 블렌드한다—같은 모델 30 개가 아니라 다른 메커니즘 30 개

왜 이 단계가 필요한가. 모델 하나는 자기만의 inductive bias 가 있다. GRU 는 시퀀스 패턴식으로, ODE 는 적분식으로, 물리모델은 회전식으로 튜린다. 같은 모델을 시도만 바꿔 여러 개 평균하면 분산 (랜덤 노이즈) 은 줄지만 편향 (구조적 실수) 은 그대로 남는다. 점수를 더 올리려면 튜리는 방향이 서로 다른 모델을 섞어야 한다—그래야 한 모델이 경계 밖으로 민 샘플을 다른 모델이 안으로 당겨준다 (error decorrelation —모델들의 오차가 서로 안 닮음). 여기서 “섞는다”는 게 바로 ensemble(앙상블—여러 모델의 예측을 평균/가중평균해 하나의 더 나은 예측으로 합치는 것) 이다.

GRU와 Neural ODE가 왜 서로 다르게 틀리는지부터 그림으로 잡자. GRU는 과거 11 스텝 시퀀스에서 본 패턴을 떠올려 “이런 움직임 뒤엔 보통 여기로 가더라”로 다음 위치를 찍는다 (패턴 외삽). Neural ODE는 $dv/dt = -\text{감쇠} \cdot v + \text{신경망가속}$ 같은 운동방정식을 정해 두고, 그걸 작은 시간조각으로 적분해 미래를 굴린다. 출발 가정이 다르니 틀리는 지점도 갈린다—GRU는 학습 때 못 본 낮은 패턴 (헛갈리는 급선회)에서 어긋나고, ODE는 적분 오차나 감쇠 계수 오추정에서 어긋난다. 그래서 같은 급선회에서 한쪽이 예측을 경계 밖으로 밀면 다른 쪽은 안으로 당기고, 둘을 평균하면 어긋남이 상쇄된다. 이게 ODE 단독으로는 약해도 (내 d-001은 F0 동물) GRU와 섞으면 자산이 되는 이유다.

무엇을 하는가—공통점과 차이점. 다섯 명 모두 여러 모델을 평균 (blend)해 노이즈를 지운다는 점은 같다. 갈리는 지점은 무엇을 섞었느냐다. 상위 3명은 아키텍처가 다른 모델을 섞었다—1위는 GRU(시퀀스)+Neural-ODE(적분)+HyperPhysics(회전물리) 각 10 시드를 등가중 평균, 2위는 GRU·ODE·Frenet control-head·회전물리 4개 풀 ~40 멤버를 DE(미분진화)가중 최적화로, 3위는 HyperPhysics(주)+Kalman-GRU(보조) 2종을 OOF grid-search(w_phys=0.96)로 묶는다. 반면 4·5위는 같은 아키텍처의 seed/fold만 섞었다—4위는 단일 arch $\times (3\text{seed} \times 5\text{fold}) = 15$ 모델 균등평균, 5위는 단일 arch $\times 10\text{fold}$ 균등평균에 LightGBM 후처리 (축 (d) 참조)를 더했다. 그리고 등수가 그 순서다.

우승자	섞은 직교 축 유무	blend 방식
1 위	3 종 arch	등가중 30 모델
2 위	4 종 풀	DE 가중 2 단
3 위	2 종	OOF grid-search
4 위	seed/fold 만	균등평균
5 위	seed/fold 만	균등평균 + LightGBM

여기서 한 부품을 짚고 가자. 1위의 Neural-ODE가 한 스텝을 적분할 때 쓰는 RK4 integration. 미래 위치를 한 번에 점프하지 않고, 작은 4 걸음으로 쪼개 곡선을 정밀하게 따라가는 적분 방법이다. 미분방정식 prior를 신경망 forward 안에서 실제로 굴리는 게 이 RK4다. (정식 이름은 ‘4 차 룽게-쿠타’지만, 이 부품의 디테일—‘4 차’, ‘룽게-쿠타’같은 정밀도 용어—은 글을 따라가는 데 몰라도 지장 없다. “ODE가 미래를 작은 걸음으로 적분해 푼다”만 잡으면 된다.)

3위가 직접 측정한 바로는 “블렌딩 자체의 gain은 미미 (0.6739→0.6744)하고, 진짜 이득은 Phys 모델을 보유한 것 자체”(cell 6543~6558 안전장치)였다—즉 (c)의 핵심은 “가중치 최적화 기교”가 아니라 애초에 서로 다른 메커니즘의 강한 모델을 여러 종 갖는 것이다.

그래서 점수가 왜 오르는가. 1위의 거리분포가 carrier를 보여준다—30 모델 blend는 단일 모델 대비 예측을 평균 0.22cm 옮겼고, 그 작은 이동이 1cm 경계 샘플의 hit/miss를 뒤집어 LB +0.0168(plan-w-001.results.md §3.3·§3.4). 단, 여섯 부품 각각의 개별 ΔLB는 측정되지 않았다 (ablation plan w-2~7 미실행). 측정된 건 “전체 격차 +0.0168”과 “거리분포”뿐이다.

💡 내가 떠올렸어야 한 것] 나는 시드/cfg diversity($2\text{cfg} \times 5\text{fold} \times 3\text{seed} = 30$ 개 평균)은 이미 했다. 심지어 4위 (15 개)보다 표본은 많았다. 그런데 내 30개는 전부 같은 메커니즘 (Kalman 잔차 GRU)이었다—분산만 줄이고 편향은 그대로. 나는 plan-018에서 단일 stack으로 SetTrans/PathSig/MoLE/GRU-attn을 하나씩 교체해보고 4/4 FAIL하자 “아키텍처 diversity는 소용없다”고 단정했다. 하지만 우승자들은 교체가 아니라 블렌드했다—약한 ODE(단독 F0 동물)도 GRU와 섞으면 탈상관 자산이 된다. 이 발상은 “내 30개 예측이 서로 얼마나 상관됐나 (예측 간 상관행렬)”를 한 번만 찍어봤으면—상관행렬을 찍었으면 그 값이 거의 1에 가깝다는 걸 (아마 0.99 수준, 측정은 안 했으니 추정) 봤을 것이고—“다양성이 0 이구나, 시드가 아니라 메커니즘을 바꿔야겠다”로 바로 이어졌을 것이다.

(d) 이진 hit 지표를 정조준한다—평균 (MSE) 이 아니라 적중 (metric) 을 직접 최적화

왜 이 단계가 필요한가. 채점은 “ $\leq 1\text{cm}$ 면 1, 아니면 0”인 binary metric 이다. 그런데 보통 회귀 손실 (MSE/euclidean) 은 “평균 거리”를 줄인다. 이 둘은 미묘하게 다르다—평균 거리를 줄이려는 손실은 이미 2cm 떨어진 (어차피 miss) 샘플을 1.5cm 로 당기는 데도 똑같이 힘을 쓴다 (점수엔 0 기여). 정작 필요한 건 1.05cm 짜리 (아슬하게 miss) 를 0.95cm 로 밀어 hit 로 뒤집는 것이다. 그래서 다섯 명 전원이 1cm 경계를 미분 가능하게 훑내 낸 손실 (soft-hit) 을 손실 함수에 직접 넣는다 (metric-aligned loss).

무엇을 하는가—공통점과 차이점. soft-hit 손실은 사실상 한 식의 변주다—“거리가 1cm 보다 작을수록 1, 클수록 0 으로 가는 sigmoid(시그모이드) 계단”을 손실에 더하는 것으로, 다섯 명이 모두 이걸 euclidean/Huber/MSE 같은 거리 항과 함께 쓴다. 대표적으로 1 위의 soft-hit 항은 다음 형태다 ($\tau=0.0015$):

```
loss_softhit = -sigmoid((0.01 - dist) / tau).mean() # 1위, Cell 18
```

이 한 줄을 직관으로 풀면—sigmoid 는 입력이 0 을 넘는 순간 0 에서 1 로 부드럽게 갈아타는 S 자 스위치다. 거리 dist 가 1cm(0.01) 보다 작으면 $(0.01 - \text{dist})$ 가 양수 $\rightarrow$ 출력이 1 쪽 (hit 에 가까움), 크면 음수 $\rightarrow$ 출력이 0 쪽 (miss). 그리고 이 S 자가 가장 가파르게 꺾이는 지점이 정확히 1cm 경계라, 학습의 힘 (gradient —손실을 줄이려 모델을 미는 방향과 크기) 이 바로 거기 몰린다. τ (타우) 는 그 S 자의 폭으로, τ 가 작을수록 1cm 경계에서 기울기가 더 칼같이 꺾여 경계 샘플에 보정이 집중된다.

갈리는 지점은 이 항에 얼마의 가중을 주고, 경계 날카로움 (τ) 을 어떻게 정했나. 1 위는 가중 2.0(Huber 0.5 + 가우시안-soft 0.5 의 두 배) 으로 가장 세게 눌렀고, 2 위 Pool A 는 $\beta=0.002$ ·가중 0.3 으로 euclidean 과 함께 쓴다 (이게 내 KR008 과 동일 계수, Cell 8). 5 위는 가중 0.15 에 Huber($\delta 0.015$)+param_reg 를 곱들인다 (Cell L195). 3·4 위는 $\text{thr}=0.013012$, $k=408.348$ 로 동일한 상수를 공유한 채 $129 \cdot \text{MSE} + 0.05 \cdot \text{NLL}$ 와 함께 쓴다 (3 위 cell 6097 / 4 위 line 473).

두 가지가 눈에 띈다. (1) 1 위는 soft-hit 가중을 2.0 으로 가장 크게 줬다—metric 항을 가장 세게 눌렀다. (2) 3·4 위의 $\text{thr}=0.013012$, $k=408.348044$ 같은 소수점 6 자리 상수는 외부 베이지안 HPO(하이퍼파라미터 자동탐색) 로 튜닝된 값이다—손실의 “1cm 경계 날카로움”조차 자동탐색으로 짚었다는 뜻.

그리고 손실만이 아니라 early stopping 기준도 metric 이다—2·3·4·5 위 모두 val loss 가 아니라 val R-Hit@1cm 가 최고인 epoch 의 가중치를 저장한다 (2 위 Cell 9 / 4 위 line 524). 손실이 더 내려가도 hit 가 안 오르면 거기서 멈춘다.

그래서 점수가 왜 오르는가. 손실의 gradient 가 “경계 근처 샘플”에 집중된다. 위에서 본 sigmoid 계단은 1cm 부근에서 기울기가 가장 가파르므로, 0.9~1.1cm 샘플에 가장 큰 보정 신호가 간다—정확히 점수를 뒤집을 수 있는 샘플들이다.

[💡 내가 떠올렸어야 한 것] 이걸 내가 부분적으로 맞췄다—내 KR008 손실 $\text{euclid} + 0.3 \cdot \text{softhit}$ 은 2 위의 Pool A 와 계수까지 똑같다. 즉 나는 2 위의 “Pool A 단일 멤버”를 정확히 재현한 셈이다. 내가 못 한 건 두 가지다. (1) soft-hit 가중을 키워보지 않았다—1 위는 2.0, 나는 0.3 으로 묶어뒀다. metric 항을 더 세게 눌렀으면 어땠을지 한 번도 sweep 하지 않았다. (2) early stopping 을 metric 으로 안 했다—나는 single-phase 라 loss 기준이었다. “OOF hit 는 안 오르는데 loss 만 내려간다”를 봤으면, “그럼 멈출 기준을 hit 로 바꾸자”가 바로 나왔을 것이다. 이 두 발상은 “내 손실 곡선과 hit 곡선을 같은 그래프에 겹쳐 그려봤으면”—둘이 따로 노는 걸 봤으면—자연히 떠올랐다.

(e) K-fold·multi-seed 로 안정화—그리고 평가 기준을 OOF 에 고정한다

왜 이 단계가 필요한가. 이 지표는 이진이라 점수가 들쭉날쭉하다. 시드 하나, fold 하나 바꾸면 hit 가 ± 0.003 씩 흔들린다. 이 노이즈 위에서 “이 기법이 효과 있나?”를 판단하려면, 단일 실행이 아니라 여러 fold·시드의 평균 (OOF) 으로 봐야 한다. 안 그러면 노이즈를 실력으로 착각한다.

무엇을 하는가—공통점과 차이점. 다섯 명 모두 multi-fold·multi-seed 로 분산을 지운다는 점은 같고, 갈리는 지점은 OOF 를 어디까지 신뢰했나. 1 위만 fold 를 안 나누고 full-fit(OOF 없음) + arch 당 10 시드 blend 로 노이즈를 흡수했다. 나머지 넷은 5/10-fold 를 쓰되, 2·3 위는 blend 가중치 자체를 OOF 로 최적화했다 (2 위 5-fold·DE 가중·OOF=0.6831 / 3 위 MD5 stable 5-fold·grid-search w_phys=0.96). 4 위는 5-fold×3seed=15 모델에서 early-stop·평가를 모두 OOF hit 로 했다. 5 위는 10-fold 를 썼지만 alpha 를 OOF 가 아니라 Public LB 로 골라 실패했다.

핵심은 blend 가중치를 OOF 로 정한다는 점이다—2 위의 DE, 3 위의 grid-search(w_phys=0.96) 모두 test 가 아니라 OOF R-Hit 를 최대화하도록 가중을 뽑는다. 그리고 5 위가 반례로 교훈을 준다: 그는 LightGBM 보정의 alpha 를 OOF best 가 아니라 Public LB 를 보고 0.14 로 골랐고, 그 결과 Public 0.7022 → Private 0.700 으로 하락했다 (Cell §8 자인). “OOF 를 믿고 더 보수적인 alpha 를 골랐어야 했다”는 게 그의 회고다.

그래서 점수가 왜 오르는가 (혹은 안 무너지는가). multi-seed/fold 는 분산을 줄여“경계 샘플의 평균 위치”를 안정시킨다—30 모델 blend 는 시드 변동 $\pm 0.001 \sim 0.003$ 을 평균으로 지운다 (plan-w-001.results.md §7). 그리고 OOF 기준 선택은 Private 셔플에서 무너지지 않게 한다—5 위의 -0.0022 추락이 그 반대 사례다.

💡 내가 떠올렸어야 한 것! 이건 내 유일하게 우승자보다 강했던 축이다—나는 2cfg×5fold×3seed=30 으로, 4 위 (15)·3 위 (fold 당 1seed) 보다 표본이 많았다. 그런데 나는 정작 이 강점을 결정에 못 썼다. 내 진짜 실패는 “KR002·KR003 에서 OOF 는 중립인데 LB 는 +0.006/+0.0036 오르는 CV-LB gap”를 보고도, “OOF-neutral 이니 버릴까” 망설인 것이다. 우승자들은 정반대로 행동했다—1 위는 아예 OOF 를 안 보고 full-fit + blend 로 갔고, 2·3 위는 OOF 를 가중 선택의 기준으로 신뢰했다. 나는 OOF 를 “기법을 버릴 핑계”로 썼지, “무엇을 블렌드할지 정하는 도구”로 쓰지 못했다. 이 발상은 “내 30 개 예측을 어떻게 가중 평균할까”를 한 번이라도 OOF 로 풀어봤으면 나왔다—나는 그냥 등가중 평균만 했지, OOF 로 가중을 뽑는 단계 자체가 없었다.

(f) HyperPhysics 계보를 공유한다—같은 조상 코드에서 갈라져 나왔다

왜 이게 패턴인가. 위 (b) 에서 본 gray-box physics 신경망—Rodrigues rotation + PriorBiasedLinear + θ gating + heteroscedastic NLL + 소수점 6 자리 튜닝 상수 (thr=0.013012, k=408.348044, mse_w=129.172037) —이 똑같은 상수와 똑같은 클래스 이름 (HyperPhysics_xy2) 이 여러 우승자 코드에 동시에 등장한다. 이건 우연이 아니라 공통 조상이 있다는 증거다.

무엇을 공유하는가. 계보의 뿌리는 9 위의 [LB 0.699+] 물리학 기반 추론 모델(현재 비공개) 이다. 즉 이 HyperPhysics 계보의 출발점이 9 위다. 여기서 갈라져 나온 것이:

- 1 위 의 HyperPhysics 파트 (30 모델 중 10 개): HyperPhysics_xy2, sh_thr=0.013012, sh_k=408.348044, $\theta_{thr}=1.087618$ (Cell 16)
- 3 위의 주모델: 동일 HyperPhysics_xy2, “9 위 공개모델 기반”이라 markdown 명기 (cell 5855), 동일 6 자리 상수 (cell 6007)
- 9 위 본인: 원조

세 코드의 클래스 구조·상수·forward 식이 거의 그대로 겹친다 (2 위의 Pool D 도 같은 HyperPhysics_xy2 계열). 즉 0.70 클럽의 상당수가 같은 물리 엔진을 공유하고, 차이는 그걸 무엇과 블렌드했는가 (1 위는 GRU+ODE 와, 3 위는 Kalman-GRU 와, 2 위는 3 개 풀과) 에서 갈렸다.

그래서 점수와 무슨 상관인가. 이 계보의 함의는 두 가지다. (1) 0.70 의 물리적 토대는 이미 공개 자산이었다—강한 물리 base 를 발명할 필요가 없었고, 이식하면 됐다. (2) 우승의 변별점은 물리 엔진 자체가 아니라 그 엔진을 어떤 직교 모델과 어떻게 블렌드했나 (축 c) 였다.

💡 내가 떠올렸어야 한 것] 나는 plan-004 에서 공개 PB 0.6822 노트북 (내 plan-004 framework 원본) framework 를 이식해 LB 0.6806 으로 첫 도약을 했다—즉“공개 자산 이식”이 통한다는 걸 이미 경험했다. 그리고 내 Kalman 잔차 GRU lane 도 내 Kalman-residual GRU lane 의 원본 공개 노트북 (LB 0.6780) 재현이었다. 그런데 나는 거기서 멈췄다. 0.68 짜리 공개 자산은 이식했지만, 0.699 짜리 (9 위 계보) 는 안 찾았다. 다섯 우승자가 공유한 HyperPhysics 가“공개 codeshare 에서 출발 가능한 자산”이라는 걸 알았다면, 내 lever 수확이 diminishing returns(체감—+0.0060→+0.0036→+0.0008) 하며“paradigm 종료 신호”가 왔을 때—내 paradigm 을 더 짜내는 대신 더 높은 조상으로 갈아타는 선택이 보였을 것이다. 이 발상은“내가 이식한 base 가 0.68 인데 LB 1 위는 0.70 이다, 그 사이 0.699 짜리 공개 자료가 있나”를 codeshare 에서 한 번 검색했으면 나왔다—나는 한 노트북 (내 Kalman-residual GRU lane 의 원본 공개 노트북, LB 0.6780) 을 깊게 파느라, 더 높은 base 가 공개돼 있는지를 옆으로 살피지 못했다.

종합: 여섯 축이 한 파이프라인으로 이어진다

데이터 한 궤적이 들어와서 점수가 나오기까지, 다섯 우승자의 공통 흐름:

raw 11스텝 궤적

- (a) 물리 base 깔기 (등속/Kalman/physics-core) + yaw정렬
- (b) gray-box physics 신경망이 회전 보정 (f: 공유 HyperPhysics 엔진)
- (d) soft-hit 손실 + metric early-stop 으로 1cm 경계 정조준 학습
- (e) 5/10-fold × multi-seed 로 안정화, 00F 로 가중 선택
- (c) 직교 메커니즘 (GRU·ODE·물리) blend 로 error decorrelation
- submission (1cm 경계 샘플이 안쪽으로 밀려 hit↑)

내가 한 것과 못 한 것을 한 줄로:

축	내 KR008	격차
(a) residual 학습	✓ 했다 (Kalman 잔차)	출력 표현 단일 (계수화 안 함)
(b) 물리 prior	✗ 순수 데이터 GRU	gray-box gating 부재
(c) 직교 blend	! 시드만, 메커니즘 단일	내 최대 결손
(d) metric 손실	! softhit 0.3 (2 위 Pool A 동일)	가중 약함·metric early-stop 없음
(e) multi-seed	✓ 30 개 (우승자보다 많음)	OOF 를 선택 도구로 못 씀
(f) 계보 공유	✗ 0.68 자산만 이식	0.699 조상 미탐색

가장 정직한 결론: 다섯 명의 6-축 중 개별 ΔLB 가 측정된 건 없다 (1 위 ablation plan w-2~7 미실행). 단언 가능한 건—전체 격차는 +0.0168(1 위 vs KR008, plan-w-001.results.md §3.4) 이고, 그 carrier 는“평균 0.22cm·97.4% 가 1cm 이내인 두 예측”사이에서 1cm 경계 샘플이 어느 쪽으로 밀렸나다 (§3.3). 나는 (a)(d)(e) 는 달았고, (c) 직교 diversity 와 (b) 물리 prior 와 (f) 더 높은 조상에서 갈렸다.

4. 단계별 심층 비교 (전처리 → 피처 → 모델 → 검증 → 앙상블/후처리)

이 섹션은 이 자료의 심장이다. 같은 데이터 (11 스텝 3D 궤적 → +80ms 위치 1 점) 가 똑같이 들어왔는데, 어디서부터 내 파이프라인과 우승자들의 파이프라인이 갈라졌는지를 단계별로 해부한다. 각 단계마다 (a) 내가 한 것 → (b) 우승자들이 한 것 → (c) 💡 내가 떠올렸어야 한 것] 순으로 본다. (이하 등수는 분석 대상 0.70+5 인의 score 순이다—4 위·5 위의 정확한 DACON private 순위는 비공개.)

먼저 전체 지형을 한 장으로 깔아두자. 우리가 푸는 문제의 평가 지표는 hit@1cm metric(예측 좌표가 정답에서 1cm 이내면 1 점, 아니면 0 점인 이진 적중률) 이다. 이게 모든 설계 결정의 뿌리다—“거리를 줄여라”가 아니라“1cm 경계 안으로 밀어넣어라”가 진짜 목표다. 1 위와 내 KR008 의 예측 좌표는 평균 0.22cm 밖에 안 떨어져 있는데 (97.4%

가 서로 1cm 이내, P95 0.64cm —plan-w-001.results.md §3.3) LB 는 +0.0168 차이가 난다. 즉 격차는“큰 오차를 고친”데서 오는 게 아니라, 1cm 경계에 걸친 샘플들을 아주 조금씩 안쪽으로 밀어넣은 누적에서 온다. 이 한 문장이 아래 모든 단계를 관통한다.

단계	내 KR008	우승자 공통 패턴
1. 전처리	Kalman 잔차 + yaw 회전 (KR002 부터)	cv_1step/Kalman 잔차 + yaw/Frenet 회전 + 다중 frame
2. 피쳐	Kalman 부산물 일부 (KR003), seq 9 채널	scalar 40 종 + 물리 컨텍스트 (theta/curvature/jerk) + 노이즈 추정
3. 모델	단일 GRU(h=64)	다중 패러다임 (GRU/ODE/Frenet/회전물리/Transformer) 블렌드
4. 검증	5fold×3seed, euclid+0.3softhit	metric(R-Hit) early-stop + theta-oversample + 증강 + Soft R-Hit loss
5. 앙상블/후처리	단순 평균 (30 모델)	DE/grid 가중 블렌드 + Y-flip TTA + LGBM 잔차 보정

4-1. 전처리—“무엇을 학습할지”자체를 바꾸는 단계

(a) 내가 한 것 전처리에서 내가 한 핵심 결정은 “절대 좌표를 직접 예측하지 않는다”였다. 대신 물리 baseline 이 찍은 예측 위의 residual(residual = 정답 — baseline 예측) 만 학습했다. 내 baseline 은 Kalman filter 였고, GRU 는 “Kalman 이 틀린 만큼”만 맞추면 됐다 (EXPERIMENTS.md a-001, KR001). 여기에 두 가지를 더 얹었다:

- KR002: 입력 시퀀스를 yaw rotation —모든 궤적을“같은 방향을 보는”정면 자세로 정규화 (마지막 속도를 +x 축에 맞춰 돌려, 모든 좌회전이 똑같아 보이게 만든다). OOF 는 +0.0024(통계적 무의미) 였는데 LB 는 +0.0060 올랐다.
- KR008: 반사 + 노이즈 data augmentation(train 만) —LB +0.0008, noise floor 안.

여기서 내가 처음 마주친 게 CV-LB gap 이다. yaw rotation(KR002) 과 Kalman 부산물 (KR003) 이 둘 다 OOF(내 손안의 검증 점수) 로는 거의 안 올랐는데 LB(대회 실제 점수) 로는 각각 +0.0060, +0.0036 올랐다 (EXPERIMENTS.md a-001/a-002). 즉 내 검증 점수가 진짜 실력을 과소평가하고 있었다.

(b) 우승자들이 한 것 우승자 5 명 전원이“잔차 학습 + 회전 정규화”라는 같은 뼈대를 썼다—이 전처리 자체는 정답 이었다. 그런데 디테일에서 갈렸다.

공통점: 모두 고정 baseline(cv_1step 또는 Kalman) 위에 잔차를 얹고, 출력 잔차를 $\tanh \times 0.02m(=2cm)$ 로 묶어 보정량을 제한했다 (baseline 이 이미 거의 맞으니 outlier 폭주를 막는 것—이건 나도 KR008 에서 한 부분이다).

여기서 2 위는 Frenet frame 을 먼저 직관으로 잡고 가자 (뒤에서 계속 나온다). 내 yaw rotation 은 궤적을 하나의 평면 위에서 빙 돌려“정면을 보게”만드는 2D 회전이였다. Frenet frame(궤적을 따라가며 그 점만의 좌표축 3 개를 세우는 자연스러운 3D 기준틀) 은 이걸 3D 전체로 강화한 것이다—궤적 위의 한 점에서 진행 방향(앞), 휘는 방향(옆), 그 둘에 수직인 방향(위) 으로 그 점에 딱 붙는 좌표축 세 개를 세운다. 모기가 어느 절대 방향을 향하든 진행 방향 기준으로 좌표를 다시 그리면 모든 좌회전·우회전이 똑같은 모양으로 정렬된다 (yaw 회전의 강화판). yaw 가 평면 회전 하나라면, Frenet 은 곡선 자체에 붙은 3 축 좌표계다. 구현은 t(접선)= 마지막 속도 벡터, n(법선)= 가속도를 Gram-Schmidt(두 벡터를 서로 수직이 되게 다듬는 절차) 로 t 에 직교하게 정리, b(종법선)=t 와 n 의 외적 ($t \times n$, 두 축 모두에 수직인 세 번째 축을 만드는 연산). 단 거의 직진인 샘플은 가속도가 0 에 가까워“휘는 방향 (n)”이 정해지지 않아 (0 으로 나누는 꼴) frame 이 무너지므로 (degenerate), 그런 샘플은 다시 yaw 로 fallback(되돌림) 한다.

차이점: 1 위는 cv_1step(=last + 2·(last—prev)) baseline 에 yaw 회전. 2 위는 좌표 frame 을 두 개 (yaw rotation + 위에서 설명한 Frenet frame) 써서, 같은 궤적을 두 좌표계로 보여주고 그 예측을 앙상블한다 (degenerate 샘플 은 yaw 로 fallback). 3 위는 Kalman 잔차를 직교 fwd/right/up 과 yaw 두 frame 에 각각. 4 위는 잔차의 기준 자체를 학습형으로—Kalman 같은 고정 baseline 이 아니라 학습 가능한 gray-box physics(EMA 로 속도·가속도 gating

+ Rodrigues rotation) 를 baseline 으로 깔고 그 위에 잔차 GRU 를 zero-init 으로 얹었다 (baseline 이 좋아질수록 잔차가 작아져 분산이 준다). 5 위는 물리 디코더 1-step 에 피쳐만 정규화하는 단순 frame.

세 가지 결정적 차이를 추리면: (1) 다중 frame(2 위) —나는 단일 frame 이었다. (2) 학습형 baseline(4 위) —나는 고정 Kalman. (3) 출력 bound 2cm 는 거의 전원 공통이자 내가 유일하게 따라간 부분.

(c) 떠올렸어야 한 것

[💡 내가 떠올렸어야 한 것] 나는 yaw rotation 하나까지는 했지만, 여기서 “frame 을 여러 개 만들어 같은 궤적을 여러 관점으로 학습시킨다”는 발상을 못 했다. 2 위의 Frenet frame + yaw fallback 이 그것이다. 그 발상은 이런 관찰에서 나올 수 있었다—yaw rotation 이 OOF 는 그대로인데 LB 를 +0.0060 올렸다 (EXPERIMENTS.md a-001) 는 건, “좌표를 어떤 자세로 보여주느냐”가 모델 성능에 실제로 영향을 준다는 직접 증거였다. 회전 하나가 그만큼 도움이 됐다면, 서로 다른 회전을 여러 개 만들어 앙상블하면 더 도움이 될 것이라는 추론으로 자연스럽게 이어졌어야 했다. 나는 “yaw 가 도움이 됐다”에서 멈췄고, 우승자는 “frame 이 lever 다 → frame 을 다양화하자”로 갔다.

[💡 내가 떠올렸어야 한 것—두 번째] 나는 Kalman 을 고정 baseline 으로 박아두고 그 위 잔차만 학습했다. 4 위는 baseline 자체를 학습 가능하게 (EMA gate + Rodrigues rotation) 만들었다. 내 plan-c-001 에서 이미 단서가 있었다—F0(linear extrapolation) 를 baseline 으로 바꿔도 GRU 잔차 lift 가 Kalman 위 lift(+0.0319) 와 거의 같은 +0.0302 가 나왔다 (EXPERIMENTS.md c-001). 이걸 “잔차 GRU 의 lift 는 baseline 종류와 거의 무관하다”는 뜻이었는데, 나는 이걸 “그럼 baseline 은 아무거나 써도 되니 신경 끄자”로 읽었다. 우승자는 정반대로 “baseline 이 무관하다면, baseline 을 학습형으로 만들어 잔차를 더 작게 만들면 분산이 줄어 1cm 경계에서 유리하다”로 읽었어야 했다.

4-2. 피쳐—모델에게 “무엇을 보고 판단할지”알려주는 단계

(a) 내가 한 것 내 입력은 비교적 단순했다. 시퀀스 텐서 (상대위치·속도·가속도 채널) 에 더해, KR003 에서 Kalman 부산물 피쳐 (innovation = 관측과 예측의 차이, filtered_v = 필터가 추정한 속도, cv_ca = 등속/등가속 잔차) 를 추가했다 (EXPERIMENTS.md a-002). OOF 는 +0.0004(무의미) 였지만 LB 는 +0.0036 올라서, 또 한 번 CV-LB gap 을 봤다. 여기까지가 내 피쳐 엔지니어링의 전부다.

(b) 우승자들이 한 것 우승자들의 피쳐는 차원이 다르게 풍부했다. 2 위·3 위·4 위가 공유한 scalar features ~40 종 (시퀀스 외에 궤적 전체를 요약한 ~40 개의 스칼라 피쳐—평균/최대 속도·가속도, 방향 통계, 노이즈 추정, 이진 플래그 등으로, 모델에게 “무엇을 보고 판단할지”의 풍부한 컨텍스트를 준다) 을 보면:

- 운동학 통계: mean/max/std speed, mean/max acc, max_jerk(jerk = 가속도의 변화율로, 궤적의 급격한 변화를 포착하는 운동학 피쳐), straightness(궤적이 얼마나 직선인지를 나타내는 피쳐 = net_disp/path_len = 순변위/경로길이. 직진 샘플은 baseline 만으로 hit 하므로 straightness 가 보정 강도 판단의 신호가 된다)
- 방향 변화: turn_cos(마지막 속도와 과거 평균 속도의 코사인—얼마나 꺾였는지), theta(turn angle(θ)), theta_mean/std/trend/vel/acc(굴절각의 통계·추세·변화율)
- noise estimation features 3 종 (각 궤적의 관측 노이즈 수준을 직접 추정해 피쳐화한 것. “이 샘플을 얼마나 믿고 보정할지”의 신뢰도 신호로, 과보정으로 1cm 밖 튕김을 막는다): noise_poly2, noise_savgol, noise_loo. 세 피쳐 모두 같은 직관으로 노이즈를 잴다—“궤적에 매끈한 곡선을 적합시킨 뒤, 실제 관측 점들이 그 곡선에서 얼마나 벗어났나 (잔차)를 측정한다. 벗어남이 크면 관측이 지저분한 (노이즈 큰) 샘플이다. 셋으로 나눈 이유는 곡선을 적합시키는 방식이 서로 다르기 때문이다—noise_poly2 는 2 차 다항식을 끼워 맞춰 그 잔차의 표준편차, noise_savgol 은 Savitzky-Golay(국소 다항 평활) 곡선의 잔차, noise_loo 는 한 점씩 빼고 스플라인을 적합시켜 그 점에서의 예측 오차 (leave-one-out 잔차) 를 본다. 서로 다른 평활 방식이라 한쪽이 놓친 노이즈를 다른 쪽이 잡는다.

- 이진 플래그: `hard_turn(turn<0.5)`, `high_speed`, `high_acc`

이게 왜 중요한가? noise estimation features(`noise_poly2/savgol/loo`) 는 모델에게 “이 샘플은 관측이 지저분하니 baseline 을 더 신뢰하고, 저 샘플은 깨끗하니 잔차를 과감히 보정해도 된다”를 판단할 자료를 준다. 노이즈가 심한 샘플에서 과보정하면 1cm 밖으로 튕겨나가므로, 이 피처가 곧 1cm 적중률 방어나다.

5 위는 한 발 더 나가서 피처를 physics decoder 의 입력 컨텍스트로 썼다—`p0`, `d1v`(속도), `ap`(접선가속), `aperp`(법선가속), `d2v`, `jerk` 를 정규화하지 않고 원단위로 넘겨서 물리식이 직접 소비하게 했다. `curvature`(꺾적이 휘는 정도, 곡률 = 법선가속/속도. 회전 동역학을 기술하는 피처로 급선회 샘플 식별과 물리 디코더 입력 컨텍스트에 쓰인다), `cross_z`(2D 외적의 z 성분으로 회전 방향 (좌/우 선회) 의 부호를 나타내는 피처) 같은 회전 동역학 피처까지 넣었다.

(c) 떠올렸어야 한 것

💡 내가 떠올렸어야 한 것] 나는 Kalman 부산물 3 개를 넣어본 게 피처 작업의 전부였다. 우승자들은 noise estimation features 3 종 (`noise_poly2/savgol/loo`) 을 넣었는데, 나는 이 발상을 못 했다. 그 발상은 이런 관찰에서 나올 수 있었다—내 metric 은 1cm 이진 적중이고, 1 위와 내 예측은 평균 0.22cm 밖에 안 떨어져 있다 (`plan-w-001.results.md §3.3`). 이 말은 “각 샘플마다 얼마나 보정을 세게 할지가 hit/miss 를 가른다”는 뜻이다. 그렇다면 모델이 “이 샘플은 얼마나 믿을 만한가”를 알아야 보정 강도를 조절할 수 있고, 그 신뢰도의 직접 신호가 바로 관측 노이즈 수준이다. 나는 Kalman innovation(예측-관측 오차) 을 이미 피처로 넣어봤으면 서도 (KR003) —innovation 이 바로 “예측 곡선에서 관측이 얼마나 벗어났나”를 재는 노이즈의 한 측정치인데 —“이걸 여러 방식으로 추정해 노이즈 자체를 피처화하자”로 일반화하지 못했다. 한 개를 넣어 LB 가 올랐으면 (+0.0036), “노이즈 추정을 더 정교하게 여러 개”로 갔어야 했다.

4-3. 모델—잔차를 실제로 맞추는 핵심 엔진

(a) 내가 한 것 내 모델은 단일 GRU 였다: 1-layer GRU(hidden=64) + scalar MLP, main head + aux head(F/W 보조 타깃), 출력은 $\tanh \times 2\text{cm clip}$ (`EXPERIMENTS.md a-001`). 이게 끝이다. 단일 아키텍처. 나는 `plan-018` 에서 아키텍처를 바꿔보려 했지만 (`SetTransformer/PathSig/MoLE/GRU-attention 4` 종) 4/4 전부 FAIL 했다 (`EXPERIMENTS.md 018`) —single-stack 아키텍처를 바꾸는 lever 자체가 한계라는 걸 측정했다. 그래서 “아키텍처는 더 짜내봐야 안 나온다”고 결론 내렸다. 이 결론은 맞았지만, 내가 도출한 행동은 틀렸다 (아래 💡 참고).

(b) 우승자들이 한 것 여기가 가장 큰 격차다. 우승자들은 “하나의 아키텍처를 더 좋게”가 아니라 “서로 다른 inductive bias 의 아키텍처를 여러 개 섞었다”.

먼저 등장하는 패러다임마다 “무슨 메커니즘으로 푸는지”한 꼬리표를 달아두자 (내부 부품까지 알 필요는 없고, 이 꼬리표만 잡으면 된다):

- GRU = 시퀀스 패턴: 과거 스텝들의 패턴을 기억해 다음 위치를 추론 (내가 쓴 것).
- Neural ODE = 적분: 운동을 미분방정식으로 보고 RK4 로 시간을 따라 적분 (learned damping = 학습된 감쇠).
- Frenet control-head = 가속도/저크로 곡선 복원: 좌표를 직접 안 맞히고, “가속도·저크 (control = 운동을 만드는 제어량)”를 출력하는 머리 (head) 를 달아, 그 값들을 운동방정식에 다시 넣어 변위를 적분해 좌표를 복원한다.
- HyperPhysics = 회전 물리: Rodrigues rotation(축 둘레 회전을 계산하는 공식) 으로 벅킹 턴 (기울며 도는 선회) 을 명시적 물리식으로 푼다. angular-velocity attention-heteroscedastic NLL 같은 내부 부품은 “각속도 정보를 가중하고 불확실성까지 출력한다”정도로만 알면 충분하다.
- Transformer 스택 = 전역 주의: 시퀀스 전체를 한 번에 보며 어디에 집중할지 학습.

공통점: 5 명 모두 서로 다른 패러다임의 모델을 둘 이상 블렌드했다 (나만 단일 GRU). 반복 등장하는 패러다임은 위 다섯이다.

차이점: 1 위는 AttnGRU·Neural ODE·HyperPhysics 각 10 개씩 30 모델 등가중 블렌드. 2 위는 4 개 직교 풀—Pool A=Kalman 잔차 GRU(이게 내 KR008 과 사실상 동일한 멤버), Pool B=Neural ODE, Pool C=Frenet control-head(가속도/저크로 곡선 복원), Pool D=HyperPhysics(회전 물리). 3 위는 HyperPhysics(주, OOF 0.6739) + Kalman-GRU(보조, OOF 0.6581) 2 모델인데, 핵심 통찰이 따로 있다—블렌딩 자체 이득은 0.6739→0.6744 로 미미하고, 진짜 이득은 “GRU 계열보다 약 0.016 높은 물리 NN 을 보유한 것” 자체다. 5 위는 GRU hidden 위에 CLS-token Pre-LN Transformer(nhead4, 2layer) 를 스택하고, 좌표를 직접 예측하지 않고 physics decoder 의 6 계수를 예측한 뒤 디코더로 좌표 복원 (바로 아래에서 풀어 설명).

physics decoder(계수학습) 란 무엇인가—8 개 검토 기법 중 하나라 그림을 깔고 간다. 보통은 모델이 다음 위치를 (x,y,z) 세 좌표로 직접 맞힌다. 5 위·2 위 (Pool C)·일부 풀은 대신, 궤적을 물리적으로 의미 있는 양으로 분해해 맞힌다—진행 방향 (접선) 으로 얼마나 전진하고, 옆 (법선) 으로 얼마나 휘고, 속도가 얼마나 변하나 (저크) 같은 운동량을 출력하는 것이다. 그러면 decoder 가 이 양들을 운동방정식에 그대로 넣어 (x,y,z) 를 복원한다. 5 위가 출력한 6 계수는 대략 접선 변위·법선 변위·접선 가속·법선 가속·시간 스케일·저크 항 같은 분해량이다. 좌표 3 개를 직접 맞히는 것보다 나은 이유는 각 양에 물리적 제약을 직접 걸 수 있어서다—전진 거리는 음수일 수 없으니 softplus(출력을 항상 0 이상으로 만드는 함수) 로 $d1s \geq 0$, 휘는 양은 물리적 한계가 있으니 $\tanh \times 8$ 로 perps 를 ± 8 범위에 가두고, 시간 스케일은 $ts \in [0.6, 1.4]$ 로 묶는다. 이렇게 하면 “말도 안 되는 답”(뒤로 가거나 무한히 휘는 예측) 이 출력 단계에서 원천 차단된다.

이 다양성이 왜 점수를 올리나? 서로 다른 아키텍처는 서로 다른 종류의 실수를 한다. GRU 는 시퀀스 패턴에서, ODE 는 적분 오차에서, 물리모델은 회전 가정 위반에서 틀린다. 이 오차들이 error decorrelation(서로 다른 모델의 오차가 상관되지 않아 평균 시 상쇄되는 성질) 되어 있으면, 평균을 내는 순간 오차가 서로 상쇄된다. 1cm 경계에 걸린 샘플이 한 모델에선 1.1cm(miss) 여도 세 모델 평균에선 0.9cm(hit) 가 될 수 있다—이게 +0.0168 격차의 핵심 carrier 로 측정됐다 (plan-w-001.results.md §0, H2 확증).

모델	단일 아키텍처?	패러다임 수
내 KR008	✓ GRU 하나	1
1 위	×	3 (GRU/ODE/HyperPhysics)
2 위	×	4 (GRU/ODE/Frenet/회전물리)
3 위	×	2 (HyperPhysics/Kalman-GRU)
5 위	×	GRU+Transformer 스택

(c) 떠올렸어야 한 것

💡 내가 떠올렸어야 한 것—이 자료에서 가장 중요한 한 칸] 나는 plan-018 에서 “단일 아키텍처를 바꾸는 lever 는 한계다”(4/4 FAIL) 를 정확히 측정했다. 진단은 옳았다. 그런데 거기서 내가 내린 행동은 “아키텍처는 포기하고 다른 데서 짜내자”였다. 옳은 행동은 정반대였어야 한다—“하나로는 천장이니, 여럿을 섞자 (블렌드)”. 그 발상은 이런 관찰에서 나올 수 있었다. plan-018 이 falsify 한 건 “single-stack 아키텍처 교체”였지, “multi-stack 블렌드”가 아니었다 (plan-w-001.results.md §5 의 3 번 lesson 이 정확히 이 직교성을 지적한다). 나는 같은 데이터·같은 패러다임 위에서 아키텍처만 바꾸면 오차가 상관 (correlated) 되어 천장에 부딪힌다는 걸 봤으면서, “패러다임 자체가 다른 모델 (물리 ODE, 회전 gray-box) 을 섞으면 오차가 탈상관된다”는 다음 칸으로 못 갔다. 내가 가진 자료는 이미 충분했다—나는 Neural ODE 를 재현했고 (d-001, OOF 0.6330), F0 잔차 GRU 도 있었고 (c-001, 0.6622), Kalman 잔차 GRU(KR008, 0.6671) 도 있었다. 이 세 개를 블렌드만 했어도 2 위의 Pool A+B 구조에 근접했다. 각각이 단독으로 약해도 (ODE 는 F0 동물), 탈상관된 오차의 평균은 1cm 경계에서 이득을 낸다—이게 3 위가 “블렌드 gain 은 미미해도 이종 모델 보유 자체가 핵심”이라고 말한 바로 그 지점이다. 핵심 교훈: 단일 lever 의 한계를 측정했을 때, 그건 “이 방향을 버려라”가 아니라 “이것들을 합쳐라”의 신호일 수 있다. 나는 모델을 일렬로 비교 (누가 1 등?) 했고, 우승자는 모델을 병렬로 합산 (다 같이 쓰면?) 했다.

4-4. 검증 + 학습—“어떤 모델을 고르고, 무엇을 향해 학습하나”

(a) 내가 한 것 내 검증·학습 설정: - 손실 (loss): euclidean loss + 0.3·softhit (EXPERIMENTS.md a-001). 여기서 $\text{softhit} = \text{sigmoid}((d - 0.01) / 0.002) - 1$ cm hit 을 미분 가능하게 근사한 항을 0.3 가중으로 곱들었다. - 검증: $2\text{cfg} \times 5\text{fold} \times 3\text{seed} = 30$ 모델, OOF 평균. - early-stop / oversample / TTA / 증강: 사실상 없음 (또는 multi-phase 아닌 single-phase).

내 손실은 거리 (euclid) 가 주항이고 softhit 이 양념이었다. 즉 “평균 거리를 줄이는 것”이 주 목표였다.

(b) 우승자들이 한 것 여기서 우승자들은 학습 단계 전체를 “metric 을 직접 공격”하는 쪽으로 재설계했다. 네 개의 구체 기법으로 나눠 보자.

(1) Soft R-Hit loss —평균이 아니라 적중을 직접 최적화

1 위의 손실은 Soft R-Hit 항을 가중 $2.0 \times$ 로 지배항에 두고, Huber 0.5 + Gaussian-soft 0.5 와 합쳐 쓴다. Soft R-Hit 항은 다음과 같다 (표 밖으로 뺀다):

$\text{Soft R-Hit} = -\text{sigmoid}((0.01 - \text{dist}) / \tau) \cdot \text{mean}()$, $\tau = 0.0015$, 가중 $2.0 \times$

$\tau=0.0015$ 라는 날카로운 temperature(τ) 가 핵심이다—1cm 경계 근처에서 sigmoid 가 급격히 꺾이도록 만들어, “거리를 평균적으로 줄이는” 게 아니라 “1cm 경계 바로 밖의 샘플을 안으로 밀어넣는 데 손실의 무게가 집중”되게 한다. 5 위도 $\text{sigmoid}(-(\text{err} - 0.01) / 0.003)$ 를 0.15 가중으로 명시적 hit 항으로 썼고, 3 위·2 위·4 위는 $\text{thr}=0.013012$, $k=408.348044$ 같은 소수점 6 자리 튜닝값 (외부 Bayesian HPO 산물로 추정) 을 썼다. 손실 함수 자체를 metric 에 맞춰 정밀 튜닝한 것이다.

내 softhit 과의 결정적 차이: 내 건 euclid 가 주항 (가중 1.0), softhit 이 부항 (0.3) 이라 “거리 최소화”가 지배했다. 1 위는 Soft R-Hit 이 가중 $2.0 \times$ 로 지배항이다. 방향이 반대다.

(2) metric 기반 early-stop —val 손실이 아니라 val R-Hit 으로 모델 선택

2 위·3 위·4 위·5 위 전원이 early stopping 기준을 val loss 가 아니라 val R-Hit@1cm 으로 잡았다. “validation 손실이 가장 낮은 epoch”가 아니라 “validation 적중률이 가장 높은 epoch”의 가중치를 저장한다. 손실이 가장 낮은 지점과 적중률이 가장 높은 지점은 다르므로, 후자가 metric 에 맞는 모델을 고른다. 이것이 곧 손실·early-stop 을 모두 hit 기준으로 관찰하는 metric-aligned loss 철학이다.

(3) θ -oversample —어려운 급선회 샘플을 더 자주 보여주기

3 위·4 위·2 위 모두 WeightedRandomSampler 로 turn angle(θ) 이 큰 샘플을 oversampling 했다—가중은 $\text{theta_weights} = 1 + 4 \cdot \text{clamp}(\text{theta})$ (급커브 샘플을 최대 5 배). 왜? 직선 궤적은 Kalman 만으로도 1cm 안에 들지만, 급선회 샘플이 1cm 를 벗어나는 주범이다. metric 이 어려운 커브에서 깨지므로, 그 샘플을 집중 학습 하면 1cm 적중의 약한 고리를 보강한다. 1 위의 HyperPhysics 도 θ -가중 oversampling(급선회 최대 $5 \times$) 을 썼다.

(4) 증강 + 커리큘럼—데이터를 늘려 일반화

공통점: 모두 sliding window 다중 타깃 증강으로 한 궤적의 내부 지점들도 학습 예제로 잘라 썼다. 직관은 이렇다—나는 “11 스텝 전체 → +80ms 한 점”을 통째로 하나의 예제로만 봤지만, 한 궤적의 중간 지점들도 각각 그로부터 일정 스텝 뒤를 맞히는 별개의 예제로 잘라 쓰면 같은 데이터에서 학습 예제가 수 배로 늘어난다 (짧은 원도는 등속 외삽 또는 zero-pad+mask 로 채운다). 차이점: 1 위는 cache pretrain(실타깃 학습 전에 미리 한 번 예열 학습) 단계에서 궤적 내부 지점들까지 타깃으로 삼아 학습 예제를 약 5 배 ($\sim 50K$) 로 폭증시켰다 (interior transfer = 내부 지점도 타깃으로 전이). 2 위·3 위·4 위는 가변 길이 원도로 증식. 5 위는 한 발 더 나가 curriculum pretraining(쉬운 과제로 예열 후 본과제로 옮겨가는 단계적 학습) —궤적 중간 모든 시점을 짧은 호라이즌으로 잘라 self-supervised 대량 증강 (40ep) → 실타깃 파인튜닝 (60ep) 으로 넘어가며, 예측 계수도 단순한 4 개에서 6 개로 단계적으로 활성화했다.

(c) 떠올렸어야 한 것

💡 내가 떠올렸어야 한 것—손실] 나는 softhit 을 곁들였다 (0.3 가중, euclid 가 주향). 1 위는 Soft R-Hit loss 를 지배항으로 썼다 (2.0×). 나는 “거리를 줄이면 적중도 따라온다”고 가정했고, 우승자는 “적중을 직접 공격하자”고 했다. 그 발상은 이런 관찰에서 나올 수 있었다—내 metric 은 거리가 아니라 1cm 이진 적중이다. 그리고 1 위와 내 예측은 평균 0.22cm 밖에 안 떨어져 있다 (plan-w-001.results.md §3.3). 거리는 거의 같은데 적중률이 다르다는 건, “평균 거리를 더 줄이는 것”으로는 이미 한계에 왔고 “1cm 경계에 정확히 걸린 샘플들만 골라 밀어넣어야 한다”는 신호였다. 그러려면 손실의 무게가 경계 (τ 를 0.0015 처럼 날카롭게) 에 집중돼야 하는데, 내 0.3 가중 softhit 은 그 무게가 너무 약했고 temperature(0.002) 도 그 의도를 살릴 만큼 지배적이지 않았다.

💡 내가 떠올렸어야 한 것—early-stop 과 oversample] 나는 early stopping 을 어떤 기준으로 잡을지 깊이 고민하지 않았고 (single-phase), oversampling 은 전혀 안 했다. 우승자 전원은 val R-Hit 으로 모델을 고르고, 급선회 샘플을 5 배 oversample 했다. 그 발상은 이런 관찰에서 나올 수 있었다—내가 KR002/KR003 에서 CV-LB gap 을 두 번이나 봤다 (OOF 는 그대로인데 LB 만 +0.0060, +0.0036). 이건 “내 검증 지표 (OOF 가 손실 기반이었다면) 가 실제 적중과 어긋난다”는 경보였다. 만약 내가 OOF 를 손실이 아니라 R-Hit@1cm 으로 직접 측정·early-stop 했다면, OOF 가 LB 를 더 충실히 따라왔을 것이고 괴리가 줄었을 것이다. 그리고 “어디서 점수를 잃나”를 물었다면—급선회 샘플이 1cm 를 벗어나는 주범이라는 데 도달했을 것이고, 그게 곧 θ -oversample(1+4·clamp(θ)) 의 동기다. 나는 “전체 평균 손실”만 보느라 “어떤 부분집합에서 metric 이 깨지는가”를 묻지 않았다.

💡 내가 떠올렸어야 한 것—증강] 나는 KR008 에서 반사 + 노이즈 data augmentation 을 시도했지만 LB +0.0008(noise floor) 에 그쳤다. 우승자들은 시간축을 활용한 증강 (궤적 내부 지점도 타깃으로, sliding window 다중 타깃) 으로 데이터를 수 배 ~ 수십 배 늘렸다 (1 위 cache pretrain $\approx$ 50K). 그 발상은 이런 관찰에서 나올 수 있었다—나는 “11 스텝 $\rightarrow$ +80ms 1 점”을 하나의 고정 문제로만 봤다. 하지만 한 궤적의 모든 내부 지점이 곧 “과거 N 스텝 $\rightarrow$ 다음 위치”예제다 (1 위의 interior transfer). 입력을 좌우로 반사하는 공간 증강 (내가 한 것) 은 noise floor 였지만, 시간축으로 원도를 슬라이딩하는 증강은 진짜 새 예제를 만든다—같은 데이터에서 수만 개 학습예제를 뽑아내는 이 발상을 나는 못 했다.

4-5. 앙상블 / 후처리—마지막 한 방울을 짜내는 단계

(a) 내가 한 것 내 앙상블은 단순 평균이었다—2cfg × 5fold × 3seed = 30 모델의 OOF/예측 평균 (EXPERIMENTS.md a-001). 여기엔 가중치 최적화가 없다 (모두 동일 가중). test-time augmentation (TTA) 없음, LightGBM 후처리 없음. 끝나면 바로 제출.

(한 가지 내가 우승자보다 나았던 점: 나는 multi-seed × multi-cfg=30 모델이었는데, 3 위·4 위는 fold 당 단일 seed 였다. 시드 다양성은 내가 더 챙겼다.)

(b) 우승자들이 한 것 (1) 가중 블렌드 (단순 평균 대신 최적화)

- 2 위: base 40 멤버를 weighted blend (DE)(Differential Evolution, 미분진화—가중치 조합을 진화적으로 탐색하는 최적화) 로 가중 최적화 후, 회전물리 0.40 과 2 단 블렌드—최종 = 0.60·base + 0.40·phys_ens3. (단, DE 가중 최적화 코드 자체는 압축 내장으로 비공개.)
- 3 위: OOF grid-search 로 $w \in [0, 1]$ 을 0.02 간격 스위치해 OOF R-Hit 최대화 $\rightarrow w_{\text{phys}}=0.96, w_{\text{kal}}=0.04$. 안전장치로 블렌드 gain 이 0.0001 미만이면 phys-only 로 fallback.

(2) Y-flip TTA (1 위만 명시적으로 추론 TTA)

1 위는 추론 시 좌우대칭 (Y-flip) 입력도 예측해 평균한다—모기 궤적의 좌우 대칭성을 활용해 같은 샘플을 두 관점으로 예측하고 평균. EMA decay 0.9 도 함께. (주의: 2 위·3 위·4 위·5 위는 추론 TTA 를 안 썼다—Y-flip mirror 는 train-time 증강으로만 사용. TTA 는 1 위의 차별점.)

(3) LGBM 후보정 (5 위만)

5 위는 신경망 예측 위에 LightGBM 으로 잔차를 한 번 더 보정했다: - 메타피쳐 (seq 평탄화 + 물리 컨텍스트 + base_pred + move 등) 로 y_{res} = 정답 - OOF 예측을 학습. - boundary-weighted sample_weight(1cm 경계 근처 샘플에 더 큰 학습 가중치를 줘 그 샘플들을 집중적으로 안쪽으로 미는 기법): $err > 1cm \rightarrow 1.5$, $1cm < err < 1.3cm$ (경계) $\rightarrow 2.0$, $0.8cm < err \leq 1cm \rightarrow 1.3$ —1cm 경계 근처 샘플을 가장 무겁게 학습시켜 그 샘플들을 안쪽으로 민다. - 알고 강규제 (max_depth3, num_leaves24, min_child120, reg_lambda2.0) 로 잔차 노이즈 압기 방지. - residual clip(RESIDUAL_CLIP=0.0035 —LGBM 보정량을 촉당 일정 폭으로 제한해 과보정을 막는 안전장치. baseline 이 거의 맞을 때 보정이 폭주하면 오히려 1cm 밖으로 튕기는 걸 방지) 으로 촉당 보정폭 제한, $pred_final = final_all + 0.14 \cdot res_test$.

다만 5 위는 이 단계에서 실수도 남겼다—alpha(0.14) 를 OOF 가 아니라 Public LB 를 보고 골라서 Private 에서 0.7022 $\rightarrow$ 0.700 으로 하락했고, 본인이 “OOF 를 믿고 더 보수적인 alpha 를 골랐어야 했다”고 자인했다. (참고로 1 위·2 위·3 위·4 위는 LGBM 후처리·calibration(예측의 신뢰도/스케일을 사후 보정하는 단계)·clip 일절 없이 단순 블렌드 후 바로 제출했다. LGBM 후보정은 보편 정답이 아니라 5 위만의 선택이다.)

후처리	가중 블렌드	TTA	LGBM 보정
내 KR008	× 단순 평균	×	×
1 위	등가중 (30 모델)	✓ Y-flip	×
2 위	✓ DE+2 단 (0.6/0.4)	×(train 만)	×
3 위	✓ grid w=0.96	×	×
5 위	fold 평균	×	✓ 경계가중

(c) 떠올렸어야 한 것

💡 내가 떠올렸어야 한 것—가중 블렌드] 나는 30 모델을 단순 평균했다. 우승자들은 OOF 로 가중치를 최적화했다 (3 위의 grid-search w=0.96, 2 위의 DE). 단순 평균은 약한 모델과 강한 모델을 똑같이 취급해 강한 모델의 신호를 희석한다. 그 발상은 이런 관찰에서 나올 수 있었다—3 위에서 보듯, 강한 모델 (Phys OOF 0.6739) 과 약한 모델 (Kalman 0.6581) 을 0.96:0.04 로 두는 것이 50:50 평균보다 낫다. 내가 ODE(F0 동물 ~0.633) 와 Kalman-GRU(0.6671) 를 만약 섞었다면, 이 둘을 동일 가중으로 평균하는 건 약한 ODE 가 강한 GRU 를 끌어내리는 짓이었다. OOF 가 있으니, OOF 위에서 가중치를 grid-search 만 했어도 강한 모델에 무게를 실어줄 수 있었다—그리고 나는 multi-seed OOF 를 이미 갖고 있었으니 이 도구가 손안에 있었다.

💡 내가 떠올렸어야 한 것—TTA] 나는 train-time data augmentation(반사·노이즈) 은 시도했지만, 같은 변형을 추론 시점에 적용해 예측을 평균하는 test-time augmentation (TTA) 는 안 했다. 1 위는 Y-flip TTA 로 좌우대칭 예측을 평균했다. 그 발상은 이런 관찰에서 나올 수 있었다—나는 train 에서 반사 증강이 도움이 될 거라 가정해 이미 좌우대칭을 데이터에 썼다 (KR008). train 에서 좌우대칭이 의미 있는 변형이라고 믿었다면, 추론에서도 같은 변형의 예측을 평균하면 분산이 줄어든다는 건 한 걸음 거리였다. 1cm 경계 샘플은 단일 예측의 작은 흔들림으로 hit/miss 가 갈리는데 (plan-w-001.results.md §3.3), TTA 평균은 바로 그 흔들림을 줄여 경계 샘플을 안정화한다. 단, TTA 를 안 쓴 우승자도 4 명이나 되므로, 이걸 “반드시 했어야 할 것”보다는 “1 위가 추가로 짚낸 1cm 경계 안정화 lever”로 보는 게 맞다.

💡 내가 떠올렸어야 한 것—LGBM 후보정] 나는 후처리를 아예 안 했다. 5 위는 신경망 예측 위에 boundary-weighted LightGBM 잔차 보정을 엮었다—1cm 경계 (0.8~1.3cm) 샘플에 sample_weight 1.3~2.0 을 줘서 그 샘플들을 집중적으로 안쪽으로 밀고, ± 0.0035 residual clip 으로 과보정을 막았다. 그 발상은 이런 관찰에서 나올 수 있었다—내 격차의 carrier 가 1cm 경계 샘플의 작은 시프트라는 건 plan-w-001.results.md §3.3

에서 측정으로 나왔다 (평균 0.22cm 차이, 97.4% 가 1cm 이내). 격차가“경계 샘플”에 집중돼 있다면, 후처리도 정확히 경계 샘플만 골라 (0.008~0.013m) 가중하는 게 자연스러운 수순이었다. 신경망이 놓친 마지막 0.2cm 를 트리 모델이 메타피처로 보정하는 이 단계를, 나는“모델 학습이 끝나면 제출”로 건너뛰었다. 동시에 5 위의 실패에서 배울 점도 있다—그는 보정 강도 ($\alpha=0.14$) 를 OOF 가 아니라 Public LB 를 보고 골라 Private 에서 하락했다 (본인 자인). 역설적으로, 내가 그토록 망설였던 “OOF 를 믿을 것이냐”의 답이 여기 있다. 나는 CV-LB gap 때문에 OOF 를 못 믿어 OOF-neutral 한 lever 를 버릴까 망설였지만 (yaw·Kalman 부산물), 5 위는 OOF 를 안 믿어서 졌다. 교훈: OOF 가 LB 와 어긋날 때 답은“OOF 를 버린다”가 아니라 “OOF 를 metric(R-Hit) 에 맞게 고쳐서 신뢰도를 회복한다”(4-4 의 metric early-stop) 였다.

4-6. 단계별 요약—내 부재의 지도

단계	내가 멈춘 지점	다음 칸 (우승자)	그 칸으로 가는 관찰
전처리	yaw 회전 1 개	다중 frame(Frenet+yaw) / 학습 형 baseline	“yaw 가 LB +0.0060 = frame 이 lever”
피처	Kalman 부산물 3 개	노이즈 추정 3 종 + 물리 컨텍스트	“보정 강도 조절엔 신뢰도 신호 필요”
모델	단일 GRU(arch lever 한계 측정)	이중 패러다임 블렌드	“single-stack 한계 $\neq$ multi-stack 한계”
검증/학습	euclid+0.3softhit, 단순 평균 학습	Soft R-Hit 지배항 / metric early-stop / θ -oversample / 시간축 증강	“거리는 같은데 적중이 다르다 → 경계·부분집합 공격”
양상블/후처리	단순 평균, 후처리 0	OOF 가중 블렌드 / Y-flip TTA / 경계가중 LGBM	“격차 carrier = 1cm 경계 샘플 시 프트”

관통하는 한 줄: 나는 매 단계에서“효과적인 lever 하나”를 찾아 멈췄고, 우승자는 그 lever 를“다양화 (frame·모델·손실·가중)”하거나“metric 의 약한 고리 (경계 샘플·급선회)”로 정조준했다. 그리고 그 모든 정조준의 과녁은 동일했다—평균 0.22cm 차이로 결판나는 1cm 경계다.

위 💡 블록들은 “개념적으로 떠올려야 할 도약”을 말하는 것이지, 각 기법의 정량 기여 (per-lever Δ LB) 를 주장하는 게 아니다—1 위의 6 개 component(3-arch / 공통 backbone / Soft R-Hit / cache pretrain / Y-flip TTA / θ -oversample) 각각의 개별 Δ LB 는 아직 측정되지 않았다 (ablation 미실행). 단언할 수 있는 수치는 (1) 1 위 전체가 KR008 대비 LB +0.0168, (2) 두 예측의 평균 거리 0.22cm·97.4% within 1cm·P95 0.64cm(plan-w-001.results.md §3.3), (3) 내 lever 들의 측정 OOF/LB(yaw +0.0060, Kalman 부산물 +0.0036, aug +0.0008) —이 세 묶음뿐이다.

5. 우승자 간 차이 (0.70+ 안에서 갈리는 선택)

앞 섹션까지는“0.70 벽을 넘은 사람들은 뭘 했나”를 한 덩어리로 봤다. 그런데 막상 0.70+ 안으로 들어가 보면, 그 위에 올라선 5 명조차 서로 전혀 다른 길로 갔다. 누구는 모델을 30 개 쌓았고, 누구는 단 2 개로 끝냈다. 이 섹션의 목적은 그 다섯 노선을 나란히 놓고“복잡도를 키운 쪽이 이긴 건가? 아니면 단순함이 이긴 건가?”를 가려내는 것이다. 결론부터 말하면—복잡도가 점수를 보장하지 않았다. 다섯 노선의 점수 차는 0.0035 에 불과하다. 갈린 건 점수가 아니라“어디에 노력을 쏟을지에 대한 철학”이었다. (이하 등수는 분석 대상 0.70+ 5 인의 score 순이다—4·5 위의 정확한 DACON private 순위는 비공개.)

5.1 다섯 노선을 한 장에 (점수는 거의 같다)

먼저 사실관계부터. 다섯 노선의 Private 점수와 핵심 노선은 이렇다 (DACON comp 236716 codeshare 기준).

순위	Private	한 줄 노선	모델 수
1 위	0.7035	GRU + Neural ODE + HyperPhysics 30 모델 등가중 블렌드	30
2 위	0.7031	4-패러다임 직교 multi-pool + 2 단 블렌드	~40
3 위	0.7019	HyperPhysics + Kalman-GRU 2 모델 OOF grid-search 가중평균	2
4 위	0.7011	단일 physics-core+GRU arch 를 K-fold×seed 다중화 (15)	15 (1 arch)
5 위	0.700	GRU+Transformer 물리 디코더 + LGBM 후보정	10 (1 arch) + LGBM
(참고) 내 KR008	LB 0.6862 / OOF 0.6671	단일 Kalman 잔차 GRU	30 (1 arch)

세로로 점수 칸만 읽어보자. 0.7035 → 0.7031 → 0.7019 → 0.7011 → 0.700. 1위와 5위의 차이가 겨우 0.0035 다. 그런데 같은 표에서 “모델 수” 칸을 보면 30 개부터 2 개까지 천차만별이다. 즉, 모델을 15 배 더 쌓아도 점수는 0.0035 밖에 안 벌어졌다. 이게 이 섹션 전체를 관통하는 사실이다. 0.70 위에서는 “더 많이”가 “더 높이”를 의미하지 않는다.

내 위치도 같이 보자. 내 최고 KR008 은 LB 0.6862 다. 1 위 (notebook self-LB 0.7035) 와는 -0.0173, 5 위 (0.700) 와는 -0.0138 차이다 (EXPERIMENTS.md). 이 표를 보면 묘한 위안과 동시에 묘한 좌절이 온다—나도 모델 30 개를 양상블했다. 그런데 내 30 개는 전부 “같은 단일 arch(Kalman 잔차 GRU) 의 cfg/fold/seed 변형”이었고, 1 위의 30 개는 “3 종 서로 다른 arch × 10 개”였다. 같은 30 이라는 숫자가 전혀 다른 의미였던 것이다. 이 차이가 왜 결정적인지가 5.3 의 핵심이다.

5.2 노선별로 “무엇이 다른가”—한 줄 요약이 아니라 축으로

다섯 노선이 정확히 어느 축에서 갈렸는지를 표로 분해하면 이렇다. (각 셀의 근거는 해당 우승자 notebook 추출 기록.) 표 읽는 법: 아래 표의 행 이름 (아키텍처 다양성 / 잔차 베이스 / 블렌드 방식 / 증강 / oversample / TTA / 후처리 / 다중화 축) 은 §3·§4 에서 이미 한 축씩 다룬 “우승의 여섯 축”이다—행 이름이 낯설면 해당 절로 돌아가 그 축의 정의를 먼저 보고 오면 이 교차표가 한눈에 읽힌다.

축	1 위	2 위	3 위	4 위	5 위
아키텍처 다양성	3 종 (AttnGRU/N-ODE/HyperPhysics)	4 종 (GRU/NODE/Frenet-control/회전물리)	2 종 (HyperPhysics/Kalman-GRU)	1 종	1 종 (GRU+Transformer)
잔차 베이스	cv_1step	Kalman (등속 KF)	Kalman (등속 KF)	physics-core (EMA 등속 + 등가속)	물리 디코더 (6 계수)
블렌드 방식	등가중 평균	base DE 가중 + 회전 물리 2 단	OOF grid-search w=0.96	등가중 평균	fold 등가중 평균
증강 (train)	Y-flip + noise + cache pretrain	Y-flip mirror + 슬라 이딩 원도	슬라이딩 원도	슬라이딩 원도 + 등속 외삽 패딩	커리큘럼 멀 티-horizon
oversample	θ-가중 (급선회 5×)	θ-가중	θ-가중 (급선회 5×)	θ-가중	(커리큘럼이 대체)
TTA(inference)	Y-flip TTA	없음	없음	없음	없음
후처리	없음	없음	phys-only fallback	없음	LGBM 잔차 보정
다중화 축	arch×10	pool× 멤버	fold×2 모델	seed×fold (15)	fold (10)

이 표에서 읽을 수 있는 핵심 패턴 세 가지.

1. 공통분모가 압도적으로 많다. “잔차 학습 (residual learning, 물리 baseline 위에 NN 이 작은 보정만 학습)”, “soft-hit loss(1cm 이진 적중을 sigmoid 로 미분가능하게 근사)”, “θ-가중 oversampling(급선회 샘플을 더 자주 학습)”, “metric 기반 early-stop(val loss 가 아니라 val hit-rate 로 best epoch 선택)”—이 네 가지는 5 명 중 4~5 명이 공유한다. 즉 0.70 진입의 “입장권”은 거의 정해져 있고, 노선 차이는 그 위의 선택지였다.

- 다양성을 어디서 만들었는지가 갈렸다. 1 위·2 위는“아키텍처 종류”로 다양성을 만들었고 (서로 다른 inductive bias = 서로 다른 오차 패턴 = 평균 시 오차 상쇄), 4 위·5 위는“같은 arch 의 seed/fold”로만 다양성을 만들었다. 3 위는 그 중간—arch 2 종이되 블렌드는 거의 phys 단독 (w=0.96).
- 재현 난이도가 점수와 무관하게 천차만별이다. 2 위는 base 40 멤버가 zlib+base64 로 노트북에 압축 내장되어 멤버별 학습 코드가 비공개다 (Cell 22 MD). 재학습에 15~20 시간이 든다고 본문이 밝힌다. 반면 3 위는 모델 2 개·셀 몇 개로 끝나 누구나 한나절이면 재현한다. 점수는 0.7031 vs 0.7019 로 0.0012 차이인데, 재현 난이도는 수십 배 차이다.

5.3 1 위는 왜 30 개였나—그리고 그게 정말 효과였나 (정직하게)

1 위를 따로 보는 이유는, 내가“모델 30 개 앙상블”이라는 표면적 형태를 똑같이 했는데도 -0.0173 뒤졌기 때문이다. 무엇이 진짜 달랐나?

1 위의 30 개는 AttnGRU×10 + Neural ODE(RK4)×10 + HyperPhysics(gray-box)×10 이다 (rank1 노트북). 세 arch 는 같은 backbone(cv_1step base + yaw 회전 잔차) 을 공유하지만 예측 메커니즘이 근본적으로 다르다—GRU 는 데이터 패턴, Neural ODE 는 미분방정식 적분, HyperPhysics 는 Rodrigues 회전 물리식. 메커니즘이 다르면 틀리는 지점도 다르다. 그래서 평균을 내면 서로의 오차가 상쇄된다 (탈상관). 내 30 개는 전부 GRU 라서 다 비슷한 곳에서 틀렸고, 평균을 내도 그 공통 오차는 안 줄었다.

그 위에 1 위가 더 얹은 것들 (plan-w-001.results.md 기준): Soft R-Hit loss(평균거리 (MSE) 가 아니라 1cm 적중 자체를 직접 최적화하는 손실—sigmoid 로 적중 여부를 미분가능하게 만들어 $\tau=0.0015$, 가중 $2.0\times$ 로 최소화), cache pretrain (interior transfer)(한 궤적의 내부 지점들도 타깃으로 삼아 10K → 50K 학습예제로 증강), Y-flip TTA(추론 시 좌우대칭 입력도 예측해 평균), 그리고 HyperPhysics 의 θ -가중 oversampling(급선회를 최대 $5\times$ 더 자주 학습). 손실 형태를 정확히 쓰면 다음과 같다.

`SoftRHit = -sigmoid((0.01 - dist) /  $\tau$ ).mean(),  $\tau = 0.0015$ , weight =  $2.0\times$`

여기서 한 가지는 분명히 해 줘야 한다. 위 6 개 component(3-arch / backbone / Soft R-Hit / cache / TTA / θ -oversample) 의 개별 기여도 (per-lever ΔLB) 는 측정되지 않았다—후속 ablation plan(w-2~7) 을 실행하지 않았기 때문이다 (plan-w-001.results.md). 그래서“3-arch 가 +X, TTA 가 +Y”식의 분해는 이 자료에 없고, 지어낼 수도 없다. 실제로 단언할 수 있는 측정값은 두 가지뿐이다:

- 전체 격차: 1 위가 내 KR008 대비 LB +0.0168 (재현 환경에서 측정, plan-w-001.results.md:135).
- 예측 거리분포: 1 위와 KR008 의 예측 좌표는 평균 0.22cm 밖에 안 떨어져 있고, 97.4% 가 1cm 이내, P95 가 0.64cm 다 (plan-w-001.results.md:118-125).

이 두 번째 수치가 §1 에서 본“경계 carrier”논증의 핵심 증거다 (거리분포가 왜 격차의 정체를 드러내는지는 §1 에서 이미 풀어 설명했으니, 여기서는 그 결론만 1 위에 적용한다). 두 모델의 예측이 평균 0.22cm 로 이렇게 가까운데 LB 가 +0.0168 이나 벌어진 이유는, 지표가 1cm 이진 적중이기 때문이다. 정확히 1cm 경계에 걸쳐 있던 샘플들이 0.22cm 짜리 작은 보정 한 번으로 miss → hit 로 넘어간다. 즉 격차의 carrier 는“대부분의 샘플을 더 잘 맞춘 것”이 아니라“경계에 걸린 소수 샘플을 안쪽으로 살짝 밀어넣은 것”이고, 1 위의 모든 장치 (다양성 블렌드, Soft R-Hit, oversample) 는 결국 이“경계 밀어넣기”에 복무한다.

[💡 내가 떠올렸어야 한 것] 나는 모델 30 개를 앙상블했다. 하지만“30 개가 서로 다른 곳에서 틀려야 평균이 의미가 있다”는 발상을 못 했다. 내 30 개는 cfg/fold/seed 만 다른 같은 GRU 라서, 사실상 같은 모델을 30 번 평균한 것에 가까웠다. 이 발상은 내 손 안의 데이터에서 나올 수 있었다—plan-d-001 에서 Neural ODE 를 단독으로 돌렸을 때 OOF 0.6330(F0 동물) 으로“약하다”고 KILL 했는데, 단독으로 약한 게 앙상블에서도 쓸모없다는 뜻이 아니었다. 1 위에서 Neural ODE 는 단독으로 약해도 GRU 와 다른 방향으로 틀리기 때문에 블렌드의 1/3 을 차지한다. “이 모델이 단독으로 몇 점인가”가 아니라“이 모델이 내 GRU 와 다른 곳에서 틀리는가 (오차 상관이 낮은가)”를 봐야 했다. 단독 점수가 같아도 오차 상관이 낮으면 앙상블 가치는 전혀 다르다.

5.4 정반대 노선—3 위의 “2 모델 최소주의”

1 위가 “최대 다양성”이라면 3 위는 정반대의 미니멀리즘이다. 모델은 단 2 개—물리방정식 NN(HyperPhysics_xy2) 과 보조 Kalman-GRU(BiGRUAttn). 그리고 둘을 합치는 방식이 인상적이다.

각 모델을 5-fold 로 돌려 OOF 예측을 얻은 뒤, 가중치 w 를 0.0~1.0 까지 0.02 간격으로 전부 시도해 OOF hit-rate 를 최대화하는 w 를 고른다 (grid-search). 결과는 $w_{\text{phys}}=0.96$, $w_{\text{kal}}=0.04$. 즉 사실상 물리모델 단독에 Kalman-GRU 를 4% 만 양념으로 친 것이다. OOF 점수로 보면: Phys 단독 0.6739, Kalman 단독 0.6581, 블렌드 0.6744.

여기서 결정적 통찰: 블렌딩 자체의 이득은 $0.6739 \rightarrow 0.6744$ 로 거의 없다 (+0.0005). 진짜 이득은 “Phys 모델을 보유했다”는 사실 그 자체다—Phys(0.6739) 가 GRU 계열 (0.6581) 보다 OOF 로 약 0.016 높다. 3 위는 화려한 블렌드가 아니라 “좋은 물리모델 하나”를 가진 것으로 이겼다. (참고로 3 위는 notebook 본문에 Private 점수가 직접 박제돼 있지 않다—본문 수치는 OOF 0.6744 뿐이고 Private 0.7019 는 외부 리더보드 정보다.)

💡 내가 떠올렸어야 한 것] 나는 “CV-LB 괴리”를 보고 망설였다—KR002 의 yaw 회전은 OOF +0.0024(유의하지 않음) 인데 LB 는 +0.0060, KR003 의 Kalman feature 도 OOF +0.0004 인데 LB +0.0036 였다 (EXPERIMENTS.md). 나는 “OOF 로 안 오르지 버릴까” 망설였다. 하지만 3 위는 정반대로 행동했다—OOF grid-search 를 신뢰의 도구로 썼다. w 를 OOF 로 골라 0.96 을 채택했고, “블렌드 이득 < 0.0001 이면 phys-only 로 fallback”하는 안전장치까지 뒀다. 즉 OOF 를 “버릴지 말지 망설이는 근거”가 아니라 “선택을 자동으로 결정하는 객관적 기준”으로 썼다. 내가 매번 lever 를 손으로 판단하며 망설인 자리에서, 그는 OOF 숫자에 결정을 위임했다. 이 발상은 “내가 가진 OOF 가 lever 마다 흔들린다면, 그 OOF 를 판단이 아니라 탐색의 목적함수로 바꾸면 흔들림이 사라진다”는 관찰에서 나올 수 있었다.

5.5 단일 arch 를 다중화한 두 노선—4 위 & 5 위

4 위와 5 위는 나와 가장 가깝다—둘 다 아키텍처는 1 종이다. 그런데도 0.70 을 넘었다. 어떻게? 두 노선의 공통점은 “단일 arch 를 seed/fold 로 다중화”라는 형태다. 차이점은 그 단일 arch 를 어떻게 강하게 만들었느냐—4 위는 물리 코어를 키웠고, 5 위는 출력 표현과 후보정에서 승부를 봤다.

4 위 (0.7011): 단일 arch 지만 그 arch 가 “단순 GRU”가 아니라 물리코어 + 학습형 보정 하이브리드다. EMA 등속/등가속 외삽 + Rodrigues 회전 동역학 + softplus 다항 감쇠 + 방향 attention 을 쌓은 물리코어 위에, zero-init 된 잔차 GRU 가 작은 보정만 얻는다. 이걸 3 seed $\times$ 5 fold = 15 모델 등가중 평균으로 다중화했다. 핵심은 다양성을 arch 가 아니라 “표현력 있는 단일 물리 arch + seed/fold”에서 얻었다는 것. 내 KR008 과의 진짜 차이는 arch 개수가 아니라 잔차의 베이스가 Kalman 1-step 이냐, 학습형 물리 다층이냐였다.

5 위 (0.700): 단일 GRU+Transformer 지만 두 가지를 더 했다.

- 좌표를 직접 회귀하지 않고 물리 운동방정식 6 계수 (접선/법선/저크 분해) 를 회귀한 뒤 디코더로 좌표를 복원하는 physics decoder 구조다. 6 계수는 “차가 진행 방향 (접선) 으로 얼마나 갔나 / 옆 (법선) 으로 얼마나 빗나갔나 / 가속이 얼마나 급변 (저크) 했나”를 직교 좌표 대신 운동의 자연 축으로 분해한 것이고, 출력 head 마다 활성화함수로 물리적 범위를 강제해 비물리적 해를 원천 차단한다. 그 활성화함수 세 개의 의도를 풀어 쓰면 이렇다— d_{ls} = 전진 거리 (접선 방향 이동량, softplus 로 항상 ≥ 0 이 되게 해 “차가 뒤로 가는” 음수 해를 차단), p_{erps} = 옆으로 빗나간 양 (법선 성분, $\tanh \times 8$ 로 $\pm 8\text{cm}$ 범위에 묶어 옆 이탈이 과도하게 튀는 걸 막음), t_{s} = 시간 보정배율 (예측 구간의 시간 스케일, 0.6~1.4 범위, 즉 $\pm 40\%$ 로 제한해 시간축이 비현실적으로 늘거나 줄지 않게 함). (이 6 계수·활성함수 정의는 §4·§6 에서도 같은 상수로 참조되니, 이후 등장은 이 매핑을 그대로 가리킨다.)
- 경계 가중 LGBM 잔차 후보정: 1 차 예측의 잔차를 LGBM 으로 한번 더 보정 하되, hit 경계 (0.008~0.013cm) 샘플에 sample_weight 1.3~2.0 을 줘서 “경계에 걸린 애들”을 집중 보정하고, ± 0.0035 로 clip 해 과보정을 막았다.

그런데 5 위에는 반면교사도 있다. 최종 alpha(LGBM 보정 강도) 를 0.14 로 골랐는데, 이걸 OOF 가 아니라 Public

LB 를 보고 수동 선택했다. 그 결과 Public 0.7022 → Private 0.700 으로 하락했고, 본문에서 직접 자인한다: “OOF 기준을 믿고 더 보수적인 alpha 를 골랐어야 했습니다”.

💡 내가 떠올렸어야 한 것] 4 위를 보면 내 가장 큰 결손이 명확해진다—나는 잔차의 베이스를 Kalman 1-step 에 고정했다. “Kalman 잔차 GRU”라는 패러다임 안에서 GRU 쪽만 만지작거렸지 (yaw, feature, augmentation), 베이스 자체를 더 똑똑한 물리모델로 바꿀 생각을 못 했다. 4 위는 같은 “잔차 학습”틀에서 베이스를 EMA+Rodrigues 물리코어로 키웠고, 그게 잔차를 더 작고 학습하기 쉽게 만들었다. lever 수확이 체감 (+0.0060 → +0.0036 → +0.0008) 한 건 “GRU 쪽 lever 가 고갈”된 게 아니라 “베이스를 안 건드려서”였을 수 있다. 그리고 5 위의 alpha 실수는 내가 옳게 한 일을 확인시켜준다—나는 OOF 기반으로 보수적으로 갔고, 그건 약점이 아니라 강점이었다. CV-LB 괴리 앞에서 LB 를 쫓았다면 5 위처럼 Private 에서 무너졌을 수 있다.

5.6 정리—“그래도 다 0.70 을 넘었다”와 HyperPhysics 계보

다섯 노선을 트레이드오프 축으로 압축하면 이렇다.

노선	복잡도	다양성 원천	재현 난이도	Private
1 위	높음 (30 모델)	arch 3 종	중 (코드 공개, full-fit 174 분)	0.7035
2 위	매우 높음 (~40)	pool 4 종	매우 높음 (멤버 비공개, 15~20h)	0.7031
3 위	낮음 (2 모델)	arch 2 종 (사실상 1)	낮음	0.7019
4 위	중 (15 모델, 1 arch)	seed × fold	중	0.7011
5 위	중 (10 모델 +LGBM, 1 arch)	fold	중	0.700

두 가지를 기억하자.

첫째, “복잡도 ≠ 점수”다. 2 위는 ~40 멤버에 재현 불가능에 가까운데 0.7031 이고, 3 위는 2 모델에 한나절이면 재현하는데 0.7019 다. 0.0012 차이를 위해 2 위는 수십 배의 복잡도를 지불했다. 0.70 위에서 점수를 가른 건 복잡도의 양이 아니라 “좋은 물리 baseline + 경계를 직접 겨냥하는 손실/오버샘플 + OOF 를 신뢰하는 결정”이라는 입장권을 가졌느냐였다. 그리고 다섯 명 모두 결국 0.70 을 넘었다—노선이 이렇게 갈렸는데도. 정답이 하나가 아니었다는 뜻이고, 내가 닿지 못한 건 “특정 천재적 트릭”이 아니라 그 입장권 몇 장 (다양성 있는 블렌드, 표현력 있는 물리 베이스, 증강/오버샘플) 이었다는 뜻이다.

둘째, HyperPhysics 계보 공유. 1 위·2 위·3 위 세 노선 모두 핵심 또는 보조 모델로 HyperPhysics 계열 (물리방정식 inductive-bias NN) 을 썼다. 이 계보의 뿌리는 9 위가 공개했던 “[LB 0.699+] 물리학 기반 추론 모델”(현재 비공개)로, 1 위·3 위·9 위의 공통 ancestor 다 (EXPERIMENTS.md 주). 즉 상위권 노선들은 “각자 천재적으로 독립 발명”한 게 아니라, 하나의 강력한 공개 물리모델을 출발점으로 공유하고 거기서 각자 갈라져 나갔다. 3 위는 거의 그대로 썼고 (w=0.96), 1 위는 30 모델 블렌드의 1/3 로 흡수했고, 2 위는 4 pool 중 1 pool 로 넣었다.

💡 내가 떠올렸어야 한 것] 상위 3 명이 같은 물리모델 계보를 공유했다는 건, “이미 공개된 강한 베이스를 출발점으로 삼는 것”이 상위권의 표준 전략이었다는 뜻이다. 실제로 내 첫 큰 도약 (plan-004, LB 0.6806) 도 공개 PB 0.6822 노트북 (내 plan-004 framework 원본) 을 이식한 것이었다 (EXPERIMENTS.md) —나는 이 전략의 효과를 이미 한 번 경험했다. 그런데 그 뒤로는 내 Kalman-residual GRU lane 의 원본 공개 노트북 (LB 0.6780) 하나에 간혀, 9 위의 물리모델 같은 “더 강한 공개 베이스”로 갈아탈 생각을 안 했다. 한 번 효과 본 전략을 두 번째에 다시 쓰지 못한 것이다. “내 lever 가 고갈됐다”고 느낄 때, 같은 베이스를 더 쥐어짤 게 아니라 더 높은 공개 베이스로 출발점을 옮기는 것이 codeshare 대회의 정석이었다.

6. 다음 도전을 위한 체크리스트

이 섹션은 앞 장들에서 해부한 교훈을 다음 비슷한 챌린지에서 스스로 꺼내 쓸 수 있는 형태로 압축한다. 다음에 또 “짧은 시계열 → 미래 한 점 예측, 지표는 1cm 이내 적중 (hit@1cm)”같은 대회를 만나면, 코드를 짜기 전에 이 질문들을 하나씩 체크박스로 통과시켜라. 각 질문 뒤에는 (왜 이게 중요한가) → (이번 대회에서 뭐가 증거였나) → (내가 못 넘은 지점) 순서로 근거를 달았다. (이하 등수는 0.70+ 5 인의 score 순위다—4 위·5 위의 정확한 DACon private 순위는 비공개.)

먼저 이번 대회가 어떤 모양이었는지 한 줄로 다시 새기자. 입력은 11 스텝 (40ms 간격) 3D 궤적, 출력은 +80ms 뒤 위치 한 점, 점수는 정답과 1cm 이내면 1 점, 아니면 0 점인 이진 적중률 (hit@1cm) 이다 (EXPERIMENTS.md L3). 내 최고는 KR008 LB 0.6862 / OOF 0.6671 (단일 Kalman 잔차 GRU), 1 위는 LB 0.703. 격차는 +0.0168 (plan-w-001.results.md L17). 이 격차가 어디서 왔는지가 아래 모든 질문의 배경이다.

6.0 가장 먼저 새겨야 할 한 장면

본격 체크리스트 전에, 이번 대회의 핵심 그림 하나를 머리에 박아두자. 1 위와 내 KR008 의 예측 좌표는 평균 0.22cm 밖에 안 떨어져 있고, 97.4% 가 서로 1cm 이내다 (P95 0.64cm) (plan-w-001.results.md §3.3, L118). 즉 두 모델은 거의 같은 답을 내놓는데도 LB 는 +0.0168 차이가 난다.

왜? hit@1cm 은 1cm 경계선에서 hit/miss 가 갈리는 이진 지표라서, 경계에 걸친 샘플을 단 몇 mm 만 안쪽으로 밀어 넣으면 0 점이 1 점이 된다. 즉 이 대회의 점수는 “평균을 얼마나 줄였나”가 아니라 “경계 샘플을 얼마나 안으로 밀어 넣었나”가 결정한다. 아래 질문 대부분이 결국 “경계 샘플을 어떻게 더 밀어 넣을까”의 변주다.

💡 내가 떠올렸어야 한 것] 나는 loss 에 softhit 항을 0.3 비중으로 넣어 적중을 의식하긴 했지만 (EXPERIMENTS.md a-001), “내 모델과 더 나은 모델의 예측이 사실상 같은 자리에 있고, 차이는 경계 샘플 몇 mm 뿐”이라는 그림은 끝까지 그리지 못했다. 그 발상은 “OOF 가 거의 똑같은데 LB 만 자꾸 달라진다”(KR002/KR003 에서 반복 관찰) 는 사실을 ‘경계 샘플 carrier’ 가설로 번역했으면 나왔다. 그랬다면 “평균을 더 줄이는” 레버가 아니라 “경계 샘플을 더 안으로 미는” 레버 (TTA·앙상블·oversample) 에 자원을 몰았을 것이다.

6.1 □ 지표를 미분가능 근사해 직접 최적화했나?

왜 필요한가. 평가지표가 “1cm 이내면 1, 아니면 0”처럼 이진 (미분 불가) 이면, MSE 같은 평균 거리 loss 로 학습한 모델은 “지표가 진짜 보상하는 것”과 어긋난 방향으로 최적화된다. MSE 는 1mm 오차도 5mm 오차도 똑같이 “줄여야 할 거리”로 보지만, hit@1cm 관점에선 9mm→8mm 는 의미 없고 11mm→9mm (경계 통과) 만 점수다.

무엇을 하는가. 우승자 전원이 이진 hit 을 부드러운 (미분가능) sigmoid 함수로 근사해 loss 에 직접 넣었다. 공통 점은 모두 거리 d 와 1cm 임계의 차를 sigmoid 로 통과시킨 soft-hit 항을 두는 것이고, 차이는 그 비중과 다른 항과의 조합이다. 1 위는 soft R-Hit 항에 가중 $2.0\times$ 를 주고 temperature $\tau=0.0015$ 로 경계 폭을 좁혔으며, 5 위는 soft-hit 에 huber·param_reg 를 더한 3 항 loss 에서 hit 에 더 무게를 실었다. 2 위·3 위·4 위도 모두 같은 형태의 soft-hit 항을 포함한다. 적중 모드를 평균이 아니라 직접 최적화하는 것이 핵심이다.

그래서 점수가 왜 오르나. soft-hit loss 는 1cm 경계 근처의 샘플에 gradient 를 집중시킨다 (sigmoid 는 경계에서 기울기가 가장 크니까). 모델이 “이미 확실히 맞춘 샘플”이나 “도저히 못 맞출 샘플”에 힘을 빼고, 경계에 걸친 샘플을 안으로 미는 데 학습을 쏟는다. 6.0 에서 본 carrier 를 정확히 겨냥하는 것.

💡 내가 떠올렸어야 한 것] 나는 euclid + $0.3\cdot\text{softhit}$ 으로 soft-hit 을 이미 썼다. 여기까지는 달았다. 하지만 (1) softhit 비중을 0.3 고정으로 두고 끝까지 안 키웠고 (1 위는 $2.0\times$, 5 위는 huber 보다 hit 에 더 무게), (2) τ (temperature) 같은 경계 폭 파라미터를 튜닝 대상으로 보지 않았다. 우승자들의 thr/k 가 0.013012

/ 408.348044 처럼 소수점 6 자리 (외부 HPO 산물, 3 위 cell 6007) 인 걸 보면, soft-hit 자체보다 “soft-hit 의 경계 폭·비중을 지표에 맞춰 튜닝”하는 게 레버였다. 그 발상은 “내 softhit 0.3 은 어디서 온 숫자인가? 한 번 도 안 건드렸다”는 자문에서 나왔다.

6.2 □ 좌표를 직접 예측했나, 잔차/계수를 예측했나?

왜 필요한가. 절대 좌표 (x,y,z) 를 직접 회귀하면 모델이 “물리적으로 거의 정해진 부분 (등속 직진)”까지 통째로 학습해야 한다. 입력 데이터가 1 만 개로 적을 때, 이걸 낭비고 분산만 키운다.

무엇을 하는가. 공통점은 모든 우승자가 “쉬운 물리 baseline 을 먼저 깔고, 그 위 잔차 (또는 물리 계수) 만 학습”한 다는 것이다. 1 위·2 위·3 위와 내 KR008 은 등속 외삽 ($last + 2 \cdot (last - prev)$) 또는 Kalman 예측을 baseline 으로 깔고 그 잔차만 GRU 로 학습하며, 출력은 tanh 로 $\pm 2cm$ 정도로 bound 해 보정량을 물리적으로 제한한다. 차이는 출력 표현과 baseline 표현력에서 갈린다.

5 위는 좌표 대신 물리 운동방정식 6 계수 (접선/법선/저크 분해) 를 예측하고 디코더로 좌표를 복원하는데 (5 위 §5 L246-251), 여기서 activation function (활성함수—신경망의 출력값을 특정 범위로 눌러주는 함수) 을 head 마다 다르게 걸어 각 계수가 물리적으로 말이 되는 범위를 강제한다. 구체적으로 접선 가속 d1s 에는 softplus (출력을 항상 0 이상으로 만드는 활성함수) 를 걸어 음수를 막고 (전진 가속이 음수면 비물리적이니까), 법선 성분 perps 에는 tanh (출력을 -1~1 사이로 가두는 활성함수) 를 걸어 $\times 8$ 하면 ± 8 범위로 제한한다. 즉 “좌표 3 개를 자유롭게 뱉게” 두는 대신, 물리적으로 불가능한 값 자체가 나올 수 없게 출력 단에서 틀을 씌우는 것이다. 4 위는 Kalman 대신 학습형 물리코어 (EMA 등속 + 등가속 + Rodrigues 회전) 를 baseline 으로 깔고 잔차 GRU 의 마지막 Linear 를 zero-init 해 초기 보정을 0 으로 둔다 (4 위 line 316).

그래서 점수가 왜 오르나. baseline 이 정답의 대부분을 이미 맞춰주니, 모델은 작은 보정만 배우면 된다. 학습이 쉬워지고 분산이 준다. 내 lane 에서도 이게 검증됐다: FO floor 0.6320 위 잔차 GRU = 0.6622 (+0.0302), Kalman 위 잔차 GRU = 0.6639 (+0.0319) —baseline 종류와 무관하게 “잔차 학습”이 +0.03 을 가져왔다 (EXPERIMENTS.md c-001, a-001, L24 의 결론).

💡 내가 떠올렸어야 한 것] 나는 잔차 학습 자체는 제대로 했다 (Kalman 잔차 + $\tanh \times 2cm$ bound, 2 위 Pool A 와 사실상 동일 구조). 못 넘은 건 두 갈래다. (1) baseline 의 표현력: 나는 Kalman (등속) 1-step 에서 멈췄는데, 3 위·4 위·5 위는 baseline 자체에 회전 동역학 (Rodrigues)·EMA·곡률을 넣은 “학습형 물리코어”를 깔았다. baseline 이 풍부하면 잔차가 더 작아지고 경계 샘플이 더 안으로 들어온다. (2) 출력 표현의 선택: 나는 좌표 잔차를 예측했는데 5 위는 물리 계수를 예측했다. “급선회는 곡선인데 왜 직교 좌표 3 개를 따로 맞추지? 접선/법선/곡률로 분해하면 물리적으로 자연스럽지 않나?”라는 질문을 안 했다. 그 발상은 데이터를 그릴 때 “꺾적이 직선이 아니라 휘어 있다”는 걸 보면 나왔어야 한다.

6.3 □ 단일 arch 인가, 직교 다양성 앙상블인가?

왜 필요한가. 단일 모델은 자기 고유의 편향 (inductive bias) 방향으로만 틀린다. 같은 모델을 seed 만 바꿔 여러 개 평균 내도, 틀리는 방향이 같으면 오차가 상쇄되지 않는다. 오차를 상쇄하려면 “서로 다른 방식으로 틀리는” 모델들을 섞어야 한다 (= 오차 탈상관).

무엇을 하는가. 공통점은 1·2·3 위 모두 서로 다른 inductive bias 의 모델을 블렌드 (blend / ensemble —여러 모델의 예측을 평균·가중평균해 하나의 최종 예측으로 합치는 것) 한다는 것이다. 1 위는 AttnGRU·Neural ODE(RK4)·HyperPhysics(gray-box) 세 arch 를 각 10 개씩 30 모델 등가중 블렌드로 묶었고, 이 셋은 “데이터 순수 / 미분방정식 적분 / 물리 회전모델”로 서로 직교한다. 2 위는 GRU 잔차·Neural-ODE·Frenet control-head·회전물리 4 개 패러다임 풀을 base 40 멤버 DE 가중 블렌드 (0.60) 에 회전물리 (0.40) 를 얹는 2 단 블렌드로 합쳤다. 3 위는

HyperPhysics(주, OOF 0.6739) 와 Kalman-GRU(보조, OOF 0.6581) 를 grid-search 가중평균 ($w_{\text{phys}}=0.96$) 으로 섞었다. 차이는 풀의 개수와 블렌드 단수일 뿐, “서로 직교하는 arch 를 보유한다”는 골자는 같다.

그래서 점수가 왜 오르나. 여기엔 미묘한 함정이 있으니 짚자. 3 위의 블렌딩 자체 gain 은 0.6739→0.6744 로 거의 0 이었다. 즉 “섞는 행위”가 마법이 아니다. 진짜 이득은 “GRU 계열보다 약 0.016 높은 물리 NN 을 아예 보유한 것” 자체였다 (3 위 KR008 대비 분석). 1 위의 +0.0168 격차도 6-component stack 전체의 합이지, “블렌드만으로 +0.0168”이 아니다—개별 component 의 ΔLB 는 아직 측정 안 됐다 (ablation 미실행, plan-w-001 §1 H3 inconclusive). 단언할 수 있는 건 “전체 격차 +0.0168”과 “단일 arch → 다양성 블렌드”가 그 carrier 중 하나라는 것 까지다.

💡 내가 떠올렸어야 한 것] 이게 내 가장 큰 결손이다 (2 위 분석 “내 가장 큰 결손”). 나는 GRU 잔차 한 종류만 만들고, 다양화를 “ $2\text{cfg} \times 5\text{fold} \times 3\text{seed} = 30$ 개 평균”으로 했다. 그런데 이 30 개는 전부 같은 GRU 패러다임—틀리는 방향이 같으니 탈상관이 안 된다. 나는 사실상 2 위의 “Pool A 단일 멤버”를 30 번 복제한 셈이다. 못 넘은 발상은 두 단계다. (1) “seed 를 늘려도 OOF 가 안 오른다”(KR008 +0.0004 ns) 는 관찰을 “같은 편향을 복제 중이라 탈상관이 멈췄다”로 읽었어야 한다. (2) 그렇다면 다음 멤버는 다른 편향 (Neural ODE, 물리모델) 이어야 한다. 마침 내 d-001 에서 Neural ODE 를 재현해봤는데 단독 OOF 0.6330(F0 동률) 이라 “약하다”고 버렸다—하지만 약한 모델도 틀리는 방향이 다르면 블렌드에선 carrier 가 된다 (1 위가 ODE 를 1/3 비중으로 넣은 이유). “단독 성능이 낮다”와 “양상불 기여가 낮다”는 다른 질문임을 분리 못 했다.

6.4 □ 물리 prior 를 넣었나?

왜 필요한가. 데이터가 적을 때 (1 만 개), 순수 신경망은 “물리적으로 당연한 것”부터 데이터로 배워야 해서 비효율적이고, 비물리적인 답 (예: 갑자기 역방향으로 튜는 보정) 을 낼 위험도 있다. 도메인 지식 (등속·등가속·회전 동역학) 을 구조에 미리 박아두면 적은 데이터로도 안정 수렴한다.

무엇을 하는가. 우승자들이 넣은 물리 prior 구조는 크게 네 갈래다. - RK4 적분 / Neural ODE: 위치-속도 상태를 미분방정식으로 적분 (1 위 ODE lane, 2 위 Pool B, 3 위 GRUODE). 감쇠 항까지 학습한다—속도 변화율을 학습된 damping 과 신경망 가속의 합으로 둔다. - Rodrigues 회전 (banking turn): 급선회의 곡률을 명시적 회전행렬로 모델링. 과거 3 개 회전벡터를 angular-velocity attention 으로 합성 (1 위 HyperPhysics, 2 위 Pool D, 3 위·4 위 물리코어). - PriorBiasedLinear: 보정망의 weight/bias 를 0 으로 초기화하고 물리 prior_bias 버퍼를 더함 → 학습 초기 출력 = 순수 물리모델, 거기서 점진 보정 (3 위 cell 5987, 4 위 line 286). - 물리 게이팅: 회전 게이트를 선회각·속도 각각의 sigmoid 곱으로 두어, 저속·직선 구간에선 회전 보정을 억제 (2 위·3 위).

그래서 점수가 왜 오르나. HyperPhysics 계보가 우승자 다수의 공통 조상이라는 점이 방증이다—9 위가 공개한 물리학 기반 추론 모델이 1 위·3 위·9 위의 공통 ancestor 다 (HyperPhysics 계보의 출발점인 9 위). 0.70+ 우승자 5 명 중 3 명이 이 물리 NN 계보를 핵심으로 쓴다. 3 위 분석에서 “핵심 이득은 Phys 모델 보유 자체”라고 못 박은 것도 같은 얘기.

💡 내가 떠올렸어야 한 것] 나는 순수 데이터 GRU 였다 (2 위 분석 항목 9). 물리는 baseline(Kalman 등속) 에만 있고, 보정망은 prior 없는 깡통 GRU. 못 넘은 발상: “급선회 궤적은 등속이 아니라 회전(곡률) 인데, 내 baseline Kalman 은 등속만 안다. 그럼 보정망이 회전 전체를 데이터로 배워야 하는데, 1 만 개로 그게 될까?” 라는 질문. 이 질문에 닿았다면 Rodrigues 회전이나 RK4 적분을 baseline/보정망에 넣을 생각이 났을 것이다. 게다가 나는 d-001 에서 Neural ODE 를 이미 재현해놓고도 “F0 동률, final-epoch overfit”이라며 버렸다—early-stop 을 metric 기준으로 했거나 (6.7) 블렌드 멤버로 살렸으면 죽은 레버가 아니었다.

6.5 □ TTA(대칭성) 를 썼나?

왜 필요한가. 같은 궤적을 좌우로 뒤집어도 (Y-flip) 물리 법칙은 똑같이 성립한다. 즉 모기 궤적 데이터엔 좌우 대칭성이 있다. 이 대칭성을 추론 시점에 활용하면, 한 입력에 대해 “원본 예측”과 “뒤집은 입력의 예측을 다시 뒤집은 것” 두 개를 평균 내 공짜로 분산을 줄일 수 있다 (Test-Time Augmentation).

무엇을 하는가. 공통점은 우승자 다수가 데이터의 좌우 대칭성을 학습 증강으로 활용한다는 것이다 (2 위·3 위·4 위의 학습-시 mirror, sliding-window 증강). 차이는 추론 시점 TTA 에 있다—1 위는 Y-flip TTA 로 추론 시 좌우대칭 입력도 예측해 평균하고 (학습 시엔 Y-flip 50% + noise 0.02 augment, EMA decay 0.9), 2 위는 y-flip mirror 를 학습 증강에는 썼지만 추론 평균은 안 썼으며 (frame 별로 반전 축이 다름: yaw 는 y 축, Frenet 은 binormal —궤적이 휘는 평면에 수직인 축), 3 위·4 위·5 위는 추론 TTA 가 전혀 없다.

그래서 점수가 왜 오르나. 추론 TTA 는 1 위만 썼고, 나머지 우승자 4 명은 안 썼다. 그러니 TTA 가 우승의 필수 조건은 아니다 (1 위 6-component 중 Y-flip TTA 하나의 개별 ΔLB 는 §6.3 에서 말했듯 측정 안 됐다). 여기서 진짜 체크 항목은 “추론 TTA 를 썼나”보다 “데이터의 대칭성을 학습 증강으로라도 활용했나”—이건 우승자 다수가 했다.

💡 내가 떠올렸어야 한 것] 나는 증강이 0 이었다 (2 위 분석 항목 3, “나는 증강 0”). KRO08 에서 반사 + 노이즈 augmentation 을 시도했지만 LB +0.0008(noise floor) 에 그쳐 inconclusive 였다 (EXPERIMENTS.md a-003). 못 넘은 발상: (1) 추론 시점 대칭 평균—“좌우 뒤집어도 물리는 같으니, 두 예측을 평균하면 경계 샘플의 분산이 줄겠다.” 6.0 의 “경계 mm 싸움”과 연결했으면 자연히 나왔다. (2) 내 반사 증강이 noise floor 에 그친 이유가 “증강 자체가 무용”이어서가 아니라 “frame 을 안 맞춰 반전 축이 틀렸을”가능성 (2 위는 yaw frame 에선 y 축, Frenet 에선 binormal 로 축을 구분). 내 증강 실패를 “증강 무용”으로 일반화하지 말았어야 했다.

6.6 □ 어려운 구간 (급선회) 을 oversampling 했나?

왜 필요한가. hit@1cm 은 직진 구간에선 거의 다 맞고, 급선회 구간에서 주로 깨진다. 그런데 데이터엔 직진 샘플이 압도적으로 많다. 그냥 학습하면 모델이 “쉬운 직진”에 최적화되고, 점수를 가르는 급선회 샘플은 소수라 무시된다. 지표가 깨지는 곳에 학습을 집중시켜야 한다.

무엇을 하는가. 공통점은 우승자 4 명 (1·2·3·4 위) 이 선회각 (θ) 기반 WeightedRandomSampler 로 급선회 샘플을 가중 추출한다는 것이고, 그 가중식이 거의 동일하다—2 위·3 위·4 위는 모두 선회각을 0~1 로 clamp 해 $1 + 4 \cdot \text{clamp}(\theta)$ 가중을 주어 급커브를 최대 5 배 자주 뽑고 (3 위 cell 5894/6113, 4 위 line 169/490), 1 위 HyperPhysics 도 θ-가중 oversampling 으로 급선회를 최대 5× 까지 끌어올린다. 3 위는 분석에 “평가지표 r_Hit 가 어려운 커브에서 깨지므로 직접 타격”이라 명시했다. 차이가 거의 없다는 점 자체가 이 레버의 표준성을 보여준다.

그래서 점수가 왜 오르나. 직진 샘플은 이미 baseline 이 거의 맞춘다 (잔차 ≈ 0). 점수를 더 딸 여지는 오직 급선회 경계 샘플에 있다. oversample 은 학습 예산을 그쪽으로 강제로 몰아 경계 샘플을 안으로 미는 carrier 를 직접 겨냥한다. 우승자 4 명이 같은 $1+4 \cdot \text{clamp}(\theta)$ 공식을 공유한다는 건, 이게 거의 표준 레버였다는 뜻.

💡 내가 떠올렸어야 한 것] 나는 oversample 이 없었다 (2 위 분석 항목 4, “나는 oversample 없음”). 내 데이터는 모든 샘플을 동등하게 봤다. 못 넘은 발상: “내 모델은 어디서 틀리나?”를 한 번도 안 물었다. 만약 OOF 예측에서 miss 샘플을 골라 선회각 분포를 그렸다면 “miss 는 죄다 급선회”라는 그림이 나왔을 것이고, 거기서 “급선회를 더 자주 보여주자 (oversample)”가 자연히 따라왔다. 더 뼈아픈 건, 우승자들의 공식이 $1+4 \cdot \text{clamp}(\theta)$ 로 거의 외울 만큼 단순하다는 점—코드 한 줄 (WeightedRandomSampler) 이면 됐다. 어려운 곳에 학습을 몰아주는 이 한 줄을 안 넣었다.

6.7 □ early-stop·모델 선택을 loss 가 아니라 지표 기준으로 했나?

왜 필요한가. validation loss(MSE)가 가장 낮은 epoch가 hit@1cm이 가장 높은 epoch와 다를 수 있다. 6.1에서 봤듯 MSE와 hit은 다른 걸 보상하기 때문. loss 기준으로 best 모델을 고르면 지표 관점에서선 차선택을 고르는 셈이다.

무엇을 하는가. 공통점은 우승자 4명(2·3·4·5위)이 early-stop과 best-state 선택을 직접 대회 metric(R-Hit@1cm) 기준으로 한다는 것이다—2위는 validation R-Hit@1cm 기준으로 best_state를 저장하고(loss가 아니라 metric으로 early-stop), 3위는 early stop과 best epoch를 모두 val r_Hit 최대 기준으로 두며(3위 cell 6107), 4위는 early stopping 기준이 val MSE가 아니라 val hit-rate, 5위도 val hit 기준 best_state를 저장한다. 차이는 거의 없다.

그래서 점수가 왜 오르나. 비미분 지표는 loss에 직접 넣을 순 없어도(그래서 6.1의 soft 근사를 쓴다), 모델 선택(early-stop)에는 진짜 지표를 그대로 쓸 수 있다. soft-hit으로 학습하되 best epoch는 hit@1cm 실측으로 고르면, 학습과 선택 두 단계 모두 지표를 겨냥하게 된다.

💡 내가 떠올렸어야 한 것] 내 KR008은 single-phase였고, 그래서 best epoch 선택도 loss 기준이었다(metric early-stop이 아니었다)(2위 분석 항목 8 / §3(d)와 동일 진단). 못 넘은 발상: “나는 loss에 soft-hit을 넣어 학습은 지표를 절반 겨냥했는데, best epoch는 hit이 아니라 loss로 골랐다”는 자각. 학습 loss에는 hit항을 넣으면서도, 정작 모델 선택 기준은 loss에 둔 사각지대였다. “OOF hit는 안 오르는데 loss만 내려간다”를 봤으면 “그럼 멈출 기준을 hit로 바꾸자”가 바로 나왔어야 했다. 우승자 4명이 전부 hit 기준 early-stop을 쓴 걸 보면, 이건 거의 무료 레버였다.

6.8 □ CV-LB 괴리를 OOF-neutral이니까'라고 버리지 않았나?

왜 필요한가. 이번 대회 내 lane의 가장 비싼 교훈이다. 어떤 변경이 OOF(교차검증 점수)는 안 올리는데(neutral) LB는 올리는 경우가 반복됐다. 만약 “OOF가 안 오르니 효과 없는 변경”이라며 버렸다면, 실제로 LB를 올린 레버 손으로 죽이는 것이다.

무엇을 하는가 / 이번 대회의 증거. 내 KR lane에서 CV-LB 괴리가 3번 연속 나왔다:

변경	OOF 변화	LB 변화	만약 OOF만 봤다면
KR002 입력 yaw 회전	+0.0024 (ns)	+0.0060	버렸을 것
KR003 Kalman 부산물 feature	+0.0004 (ns)	+0.0036	버렸을 것
KR008 반사 + 노이즈 aug	+0.0004	+0.0008 (noise floor)	—

(EXPERIMENTS.md a-001/a-002/a-003) 앞 두 변경은 OOF로는 “효과 없음(neutral)”인데 LB로는 +0.0060, +0.0036의 진짜 lift였다. a-002 lesson에 “OOF-neutral으로 폐기 안한 plan 설계 보상”이라 박제돼 있다.

그래서 점수가 왜 오르나(왜 괴리가 생기나). OOF는 train 데이터 내부 split이라 train 분포에만 최적화된 신호다. LB는 별도 test 분포다. 두 분포가 미묘히 다르면, “train OOF에선 안 보이지만 test엔 통하는”일반화 레버(좌표계 정렬, 물리 부산물 feature 등)가 OOF-neutral·LB-positive로 나타난다. 이것 OOF만 보고 버리면 일반화 레버를 죽인다.

다만 한 가지 단서: 괴리가 항상 “LB를 믿어라”는 아니다. 5위는 최종 블렌드 가중 alpha를 OOF가 아니라 Public LB를 보고 골랐다가 Private에서 0.7022→0.700으로 하락했다(“OOF 기준을 믿고 더 보수적인 alpha를 골랐어야”, 5위 §8). 즉 탐색 단계의 작은 레버 채택은 LB 신호도 참고하되, 최종 하이퍼파라미터(특히 블렌드 가중)는 OOF로 보수적으로—두 단계를 구분해야 한다.

💡 내가 떠올렸어야 한 것] 이건 내가 부분적으로 잘한 항목이다. KR002/KR003 에서 OOF-neutral 이었지만 폐기하지 않고 LB 를 찍어 lift 를 확인했다 (설계 보상). 그런데 못 넘은 지점은 그다음 판단이다. 나는 이 괴리를 “lever 수확 체감 (+0.0060 → +0.0036 → +0.0008 단조 감소) = paradigm 종료 신호”로 읽고 lane 을 닫았다. 하지만 같은 데이터를 다르게 읽을 수도 있었다: “내 단일 GRU 패러다임 내부의 레버는 고갈됐다. 하지만 패러다임 자체를 바꾸면 (6.3 다양성 블렌드, 6.4 물리 prior) 새 lever 광맥이 있다.” 실제로 KR008 0.6862 에서 1 위 0.703 까지 +0.0168 이 더 있었다. “한 패러다임의 수확 체감”을 “전체 헤드룸 고갈”로 착각하지 말았어야 했다—격차의 carrier 는 내가 안 건드린 다른 패러다임 (다양성·물리·oversample) 에 있었다.

6.9 □ K-fold·multi-seed 로 안정화했나?

왜 필요한가. 단일 split·단일 seed 로 측정한 점수는 운 (random init, fold 운) 에 흔들린다. 작은 lift(+0.002) 가 진짜인지 noise 인지 구분하려면, 여러 fold·여러 seed 로 평균 내 분산을 줄여야 측정 자체가 믿을 만해진다.

무엇을 하는가. 공통점은 우승자 전원이 KFold(보통 5, 5 위는 10) 로 안정화하고 fold 모델 평균을 test 에 쓰다는 것이다 (full-fit 전체 재학습은 대체로 안 함). 차이는 seed 다양성에서 갈린다—내 KR008 은 2cfg × 5fold × 3seed = 30 모델 OOF 평균으로, 이 점에선 오히려 우승자보다 강하다 (3 위는 fold 당 단일 seed, 4 위는 3seed×5fold=15, 5 위는 10fold 에 seed 1 개로 seed 다양성 없음). MD5 해시 기반 stable fold(3 위 cell 5839) 같은 디테일도 우승자마다 다르다.

그래서 점수가 왜 오르나. 안정화 자체는 점수를 크게 올리는 carrier 라기보다, 다른 레버의 효과를 정확히 측정하게 해주는 토대다. multi-seed 로 noise floor 를 알아야 “이 +0.0008 은 진짜인가”(KR008) 를 판단할 수 있다.

💡 내가 떠올렸어야 한 것] 이 항목은 내가 이미 충분히, 오히려 과하게 잘했다 (2 위 분석: “2cfg×3seed 다중 시드 앙상블은 우승자보다 오히려 강함”). 역설적 교훈이 여기 있다. 나는 안정화 (같은 패러다임 30 회 평균) 에 자원을 쏟았지만, 그건 6.3 에서 봤듯 “같은 편향을 30 번 복제”였다. multi-seed 는 분산은 줄이지만 편향 (bias) 은 한 톨도 못 줄인다. 못 넘은 발상: “30 개를 평균해도 OOF 가 안 오른다”(KR008) 는 건 “분산은 이미 다 줄였고, 남은 오차는 전부 bias(패러다임 편향)”라는 신호였다. 그 신호를 “안정화 더 해도 소용없다 → 다른 편향의 모델이 필요하다 (6.3)”로 번역했어야 했다. 안정화를 잘한 게 아니라, 안정화로 다 잡은 분산 너머의 bias 를 못 본 것이 진짜 벽이었다.

6.10 한 장 요약 체크리스트

다음 대회에서 코드 짜기 전에 이 표를 위에서 아래로 통과시켜라. “내가 한 것”열은 이번 대회 기준 자기 점검 결과이고, 기호는 ◎= 과할 만큼 충분히 함, ◐= 제대로 함, △= 절반만 함, ×= 안 함, ?= 했는지 기록 불명을 뜻한다.

#	질문	우승자 증거	내가 한 것 (KR008)	다음엔
6.1	지표를 미분가능 근사해 직접 최적화?	soft-hit loss (전원)	△ softhit 0.3 고정	비중·τ 튜닝
6.2	좌표 직접 대신 잔차/계수?	잔차 GRU·물리 6 계수 (전원)	◐ Kalman 잔차	baseline 표현력 ↑, 계수 분해 검토
6.3	단일 arch vs 직교 다양성 블렌드?	30 모델/4 풀 블렌드 (1·2·3 위)	× 단일 GRU 30 복제	다른 편향 멤버 추가
6.4	물리 prior 주입?	RK4·Rodrigues·PriorBias (3/5)	× 순수 GRU	회전 동역학·적분 구조
6.5	TTA(대칭성)?	Y-flip TTA(1 위), 학습 mirror(다수)	× 증강 0	추론 대칭 평균 + frame 별 축
6.6	급선회 oversampling?	1+4·clamp(θ) (4/5)	× 없음	WeightedRandomSampler 한 줄

#	질문	우승자 증거	내가 한 것 (KR008)	다음엔
6.7	지표 기준 early-stop?	val hit-rate (4/5)	× loss 기준 (single-phase)	best epoch = hit 실측
6.8	CV-LB 괴리를 OOF-neutral 로 안 버렸 나?	(내 lane 교훈)	○ 안 버림	탐색 =LB 참고, 최종가중 =OOF 보수
6.9	K-fold·multi-seed 안정 화?	5~10fold (전원)	◎ 30 모델 (과함)	분산 너머 bias 를 보라

한 문장으로: 나는 6.2(잔차)·6.8(괴리)·6.9(안정화) 는 했고, 6.1 은 절반 했으며, 6.3(다양성)·6.4(물리 prior)·6.5(증강/TTA)·6.6(oversample) 을 통째로 빠뜨렸고 6.7(지표 early-stop) 은 loss 기준에 머물렀다. 격차 +0.0168 (KR008→1 위) 의 carrier 는 바로 이 빠뜨린 칸들에 있었고, 그 칸들은 전부 “같은 편향 30 복제 (분산 최소화)”에 만족하지 말고, 다른 편향·물리·어려운 샘플로 경계 샘플을 더 안으로 밀었어야 한다는 한 가지 통찰로 묶인다. (단, 이 레버들의 개별 ΔLB 는 ablation 미실행—여기서 단언 가능한 측정값은 전체 격차 +0.0168, 예측 거리분포 평균 0.22cm/97.4% within 1cm, 내 lane 의 OOF/LB 실측뿐이다.)